

第五章 统计量及其分布

§ 5.1 总体与样本

§ 5.2 样本数据的整理与显示

§ 5.3 统计量及其分布

§ 5.4 三大抽样分布

§ 5.5 充分统计量

—



例 5.0.1

某公司要采购一批产品，每件产品不

是合格品就是不合格品，但该批产品总有一个不合格品率 p 。由此，若从该批产品中随机

抽取一件，用 x 表示这一批产品的不合格数，不难看出 x 服从一个二点分布 $b(1, p)$ ，

但分布中的参数 p 是不知道的。一些问题：

- p 的大小如何;
- p 大概落在什么范围内;
- 能否认为 p 满足设定要求
(如 $p \leq 0.05$) 。

§5.1 总体与个体

总体的三层含义：

- 研究对象的全体；
- 数据；
- 分布

例 5.1.1 考察某厂的产品质量，以 0 记合格品，以 1 记不合格品，则

总体 = { 该厂生产的全部合格品与不合格品 }
= { 由 0 或 1 组成的一堆数 }

若以 p 表示这堆数中 1 的比例（不合格品率），则该总体可由一个二点分布表示：

X	0	1
P	$1 - p$	p

比如：两个生产同类产品的工厂的产品的总体分布：

X	0	1
p	0.983	0.017

X	0	1
p	0.915	0.085

例 5.1.2 在二十世纪七十年代后期，美国消费者购日产SONY 彩电的热精高于购美产SONY 彩电 原因何在？

原因在于总体的差异上！

- 1979 年 4 月 17 日日本《朝日新闻》刊登调查报告指出 $N(m, (5/3)^2)$ ，日产 SONY 彩电的彩色浓度服从正态分布，而美产 SONY 彩电的彩色浓度服从 $(m-5, m+5)$ 上的均匀分布。




图 5.1.1 SONY 彩电彩色浓度分布图

表 5.1.1 各等级彩电的比例 (%)

等级		I	II	III	IV
美产	33.3	33.3	33.3	0	
日产	68.3	27.1	4.3	0.3	

5.1.2 样本

样品、样本、样本量：样本具有两重性

- 一方面，由于样本是从总体中随机抽取的，抽取前无法预知它们的数值，因此，样本是随机的变量，用大写字母 $X_1, X_2, \dots, X_n$ 表示；
- 另一方面，样本在抽取以后经观测就有确定的观测值，因此，样本又是一组数值。此时用简单起见，无论是样本还是其观测值，样本一般均用小写字母 $x_1, x_2, \dots, x_n$ 表示；应能防止不必要的混淆以区别。

例 5.1.3 啤酒厂生产的瓶装啤酒规定净含量为 640 克。由于随机性，事实上不可能使得所有的啤酒

净含量均为 640 克。现从某厂生产的啤酒中随机

抽取 10 瓶测定其净含量，得到如下结果：
这是一个容量为 10 的样本的观测值，
 $641, 635, 640, 637, 642, 638, 643, 643, 639, 640$
对应的总体为该厂生产的瓶装啤酒的净含量。

这样的样本称为**完全样本**。

例 5.1.4 考察某厂生产的某种电子元件的

寿命，选了 100 只进行寿命试验，得到如下数据：

表 5.1.2 100 只元件的寿命数据

寿命范围		元件数		寿命范围		元件数		寿命	
范围	元件数								
(0 24]	4	(192 216]	6	(384 408]	4				
(24 48]	8	(216 240]	3	(408 432]	4				
(48 72]	6	(240 264]	3	(432 456]	1				
(72 96]	5	(264 288]	5	(456 480]	2				
(96 120]	3	(288 312]	5	(480 504]	2				
(120 144]	4	(312 336]	3	(504 528]	3				
(144 168]	5	(336 360]	5	(528 552]	1				

表 5.1.2 中的样本观测值没有具体的数值，
 只有一个范围，这样的样本称为**分组样本**。

样本的要求：简单随机样本

要使得推断可靠，对样本就有要求，使样本能很好地代表总体。通常有如下两个要求：

- **随机性：** 总体中每一个个体都有同等机会被选入样本 —— x_i 与总体 X 有相同的分布。
- **独立性：** 样本中每一样品的取值不影响其它样品的取值 —— $x_1, x_2, \dots, x_n$ 相互独立。

用简单随机抽样方法得到的样本称为
简单随机样本，也简称**样本**。

于是，样本 $x_1, x_2, \dots, x_n$ 可以看成是
独立同分布 (*iid*) 的随机变量，
其共同分布即为**总体分布**。

设总体 X 具有分布函数 $F(x)$ ，
 $x_1, x_2, \dots, x_n$ 为取自该总体的容量为 n 的样本，
则样本**联合分布函数**为

$$F(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i).$$

总体分为有限总体与无限总体

实际中总体中的个体数大多是有限的。当个体数充分大时，将有限总体看作无限总体是一种合理的抽象。

对无限总体，随机性与独立性容易实现，困难在于排除有意或无意的人为干扰。

对有限总体，只要总体所含个体数很大，特别是与样本量相比很大，则独立性也可基本得到满足。

例 5.1.5 设有一批产品共 N 个，需要进行抽样检

验以了解其不合格品率 p 。现从中采取不放回抽样抽出 2 个产品，这时，第二次抽到不合格品的概率依赖于第一次抽到的是否是不合格品，如果第一次抽到不合格品，则

$$P(x_2 = 1 | x_1 = 1) = (Np - 1) / (N - 1)$$

而若第一次抽到的是合格品，则第二次抽到不合格品的概率为

$$P(x_2 = 1 | x_1 = 0) = (Np) / (N - 1)$$

显然，如此得到的样本不是简单随机样本。但是，当 N 很大时，我们可以看到上述两种情形的概率都近似等于 p 。所以当 N 很大，而 n 不大（一个经验法则是 $n / N \leq 0.1$ ）时可以把该样本近似地看成简单随机样本。

思考：

若总体的密度函数为 $p(x)$ ，则其样本的
(联合) 密度函数是什么？

§5.2 样本数据的整理与显示

5.2.1 经验分布函数

设 $x_1, x_2, \dots, x_n$ 是取自总体分布函数为 $F(x)$ 的样本, 若将样本观测值由小到大进行排列, 为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$, 则称 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 为有序样本,

用有序样本定义如下函数

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ k/n, & x_{(k)} \leq x < x_{(k+1)}, \quad k=1, 2, \dots, n-1 \\ 1, & x_{(n)} \leq x \end{cases}$$

则 $F_n(x)$ 是一非减右连续函数, 且满足

$$F_n(-\infty) = 0 \text{ 和 } F_n(+\infty) = 1$$

由此可见, $F_n(x)$ 是一个分布函数,
并称 $F_n(x)$ 为经验分布函数。

例 5.2.1 某食品厂生产听装饮料，现从生产线上

随机抽取 5 听饮料，称得其净重（单位：克）

这是一个容量为 5 的样本，^{351 347 355 344 351}经排序可得有序样本：

$$x_{(1)} = 344, x_{(2)} = 347, x_{(3)} = 351, x_{(4)} = 354, x_{(5)} = 355$$

其经验分布函数为

$$F_n(x) = \begin{cases} 0, & x < 344 \\ 0.2, & 344 \leq x < 347 \\ 0.4, & 347 \leq x < 351 \\ 0.8, & 344 \leq x < 347 \\ 1, & x \geq 355 \end{cases}$$

由伯努里大数定律:

只要 n 相当大, $F_n(x)$ 依概率收敛于 $F(x)$ 。

更深刻的结果也是存在的，这就是格里纹科定理。

定理 5.2.1 (格里纹科定理) 设 $x_1, x_2, \dots, x_n$ 是取自总体分布函数为 $F(x)$ 的样本， $F_n(x)$ 是其经验分

布函数， $P\{\sup_{-\infty < x < \infty} |F_n(x) - F(x)| \rightarrow 0\} = 1$

格里纹科定理表明：当 n 相当大时，经验分布函数是总体分布函数 $F(x)$ 的一个良好的近似。经典的统计学中一切统计推断都以样本为依据，其理由就在于此。

5.2.2 频数 — 频率分布表

样本数据的整理是统计研究的基础，整理数据的最常用方法之一是给出其**频数分布表**或**频率分布表**。

例 5.2.2 为研究某厂工人生产某种产品的能力，我们随机调查了 20 位工人某天生产的该种产品

的数量，数据如下

160	196	164	148	170
175	178	166	181	162
161	168	166	162	172
156	170	157	162	154

对这 20 个数据 (样本) 进行整理 , 具体步骤如下 :

(1) 对样本进行分组: 作为一般性的原则, 组数通

(2) 确定每组组距: 当在 5~20 个, 对容量较小的样本;

组距 $d = (\text{最大观测值} - \text{最小观测值}) / \text{组数};$

(3) 确定每组组限: 各组区间端点为

$$a_0, a_1=a_0+d, a_2=a_0+2d, \dots, a_k=a_0+kd,$$

形成如下的分组区间

$$(a_0, a_1], (a_1, a_2], \dots, (a_{k-1}, a_k]$$

其中 a_0 略小于最小观测值, a_k 略大于最大观测值.



(4) 统计样本数据落入每个区间的个数——频数，并列出其频数频率分布表。

表 5.2.1 例 5.2.2 的频数频率分布表

组序	分组区间	组中值	频数	频率	累
计频率 (%)					
1	(147, 157]	152	4	0.20	20
2	(157, 167]	162	8	0.40	60
3	(167, 177]	172	5	0.25	85
4	(177, 187]	182	2	0.10	95
5	(187, 197]	192	1	0.05	100
合计					2

5.2.3 样本数据的图形显示

一、直方图

直方图是频数分布的图形表示，它的横坐标表示所关心变量的取值区间，纵坐标有三种表示方法：**频数**，**频率**，最准确的是**频率 / 组距**，它可使得诸长条矩形面积和为 1。凡此三种直方图的差别仅在于纵轴刻度的选择，直方图本身并无变化。



二、茎叶图

把每一个数值分为两部分，前面一部分（百位和十位）称为**茎**，后面部分（个位）称为**叶**，然后画一条竖线，在竖线的左侧写上**茎**，右侧写上**叶**，就形成了茎叶图。如：

数值		分开		茎
		和	叶	
112	→	11 2	→	11 2
				和

例 5.2.3 某公司对应聘人员进行能力测试，测试成绩总分为 150 分。下面是 50 位应聘人员的测

试成绩（已经过排序）：


64	67	70	72	74	76	76	79	80	81
82	82	83	85	86	88	91	91	92	93
93	93	95	95	95	97	97	99	100	100
102	104	106	106	107	108	108	112	112	114
116	118	119	119	122	123	125	126	128	133

我们用这批数据给出一个茎叶图，见下页。

6	4 7
7	0 2 4 6 6 9
8	0 1 2 2 3 5 6 8
9	1 1 2 3 3 3 5 6 6 7 7 9
10	0 0 2 4 6 6 7 8 8
11	2 2 4 6 8 9 9
12	2 3 5 6 8
13	3

图 5.2.3 测试成绩的茎叶图

在要比较两组样本时，
可画出它们的**背靠背的茎叶图**。



注意：茎叶图保留数据中全部信息。当样本量较大，数据很分散，横跨二、三个数量级时，

茎叶图并不适用。

§5.3 统量及其分布

5.3.1 统计量与抽样分布

当人们需要从样本获得对总体各种参数的认识时，最好的方法是构造样本的函数，不同的函数反映总体的不同特征。

定义 5.3.1 设 $x_1, x_2, \dots, x_n$ 为取自某总体的样本，若样本函数 $T = T(x_1, x_2, \dots, x_n)$ 中不含有任

何未知参数。则称 T 为统计量。统计量的分

按照这一定义：若 $x_1, x_2, \dots, x_n$ 为样本，
则 $\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2$ 以及经验分布函数 $F_n(x)$ 都是统计量。而当 μ, σ^2 未知时， $x_1 - \mu, x_1/\sigma$ 等均不是统计量。
尽管统计量不依赖于未知参数，但是它的分布一般是依赖于未知参数的。

下面介绍一些常见的统计量及其抽样分布。

5.3.2 样本均值及其抽样分布

定义5.3.2 设 $x_1, x_2, \dots, x_n$ 为取自某总体的样本, 其算术平均值称为**样本均值** 一般用 $\bar{x}$ 表示, 即 $\bar{x}$

$$\bar{x} = (x_1 + \dots + x_n) / n$$

思考: 在分组样本场合, 样本均值如何计算?
二者结果相同吗?

样本均值的基本性质:

定理 5.3.1 若把样本中的数据与样本均值之差称为**偏差**, 则样本所有偏差之和为 0, 即

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

定理 5.3.2 数据观测值与均值的偏差平方和最小, 即在形如 $\sum (x_i - c)^2$ 的函数中,

$\sum (x_i - \bar{x})^2$ 最小, 其中 c 为任意给定常数。

样本均值的抽样分布:

定理 5.3.3 设 $x_1, x_2, \dots, x_n$ 是来自某个总体的样本,
 $\bar{x}$ 为样本均值。

(1) 若总体分布为 $N(\mu, \sigma^2)$, 则
 $\bar{x}$ 的精确分布为 $N(\mu, \sigma^2/n)$;

(2) 若总体分布未知或不是正态分布,
 但 $E(x)=\mu, \text{Var}(x)=\sigma^2$, 则 n 较大时的

渐近分

$$\bar{x} \sim AN(\mu, \sigma^2/n)$$

布为 $N(\mu, \sigma^2/n)$ 常记为
 这里渐近分布是指 n 较大时的近似分布。
 。

5.3.3 样本方差与样本标准差

定义 5.3.3 $s^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ 称为**样本方差**,

其算术平方根 $s^* = \sqrt{s^{*2}}$ 称为**样本标准差**。

在 n 不大时, 常用 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
作为样本方差,
其算术平方根也称为样本标准差。

在这个定义中, $\sum (x_i - \bar{x})^2$ 称为**偏差平方和**,
 $n-1$ 称为偏差平方和的**自由度**。其含义是:
在 $\bar{x}$ 确定后, n 个偏差 $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ 中
只有 $n-1$ 个数据可以自由变动, 而第 n 个则不
能自由取值, 因为 $\sum (x_i - \bar{x}) = 0$ 。

样本偏差平方和有三个不同的表达式:

$$\sum (x_i - \bar{x})^2 = \sum x_i^2 - (\sum x_i)^2/n = \sum x_i^2 - nx\bar{x}$$

它们都可用来计算样本方差。

思考: 分组样本如何计算样本方差?

样本均值的数学期望和方差，以及样本方差的数学期望都不依赖于总体的分布形式。

定理 5.3.4 设总体 X 具有二阶矩，即

$$E(x)=\mu < \infty, \quad \text{Var}(x)=\sigma^2 < \infty,$$

$x_1, x_2, \dots, x_n$ 为从该总体得到的样本，
 $\bar{x}$ 和 s^2 分别是样本均值和样本方差，则

$$E(\bar{x})=\mu, \quad \text{Var}(\bar{x})=\sigma^2/n, \quad E(s^2)=\sigma^2$$

5.3.4 样本矩及其函数

样本均值和样本方差的更一般的推广是样本矩，这是一类常见的统计量。

定义 5.3.4 $a_k = (\sum x_i^k)/n$ 称为样本 k 阶原点矩，

特别，样本一阶原点矩就是样本均值。

$b_k = \sum (x_i - \bar{x})^k/n$ 称为样本 k 阶中心矩。

特别，样本二阶中心矩就是样本方差。



当总体关于分布中心对称时，我们用 $\bar{x}$ 和 s 刻画样本特征很有代表性，而当其不对称时，只用 $\bar{x}$ 和 s 就显得很不够。为此，需要一些刻画分布形状的统计量，如**样本偏度**和**样本峰度**，它们都是样本中心矩的函数。

定义： $\gamma_1 = b_3/b_2^{3/2}$ 称为**样本偏度**，
 $\gamma_2 = b_4/b_2^2$ 称为**样本峰度**。

样本偏度 γ_1 反映了总体分布密度曲线的对称性信息。
样本峰度 γ_2 反映了总体分布密度曲线在其峰值附近的陡峭程度。

5.3.5 次序统计量及其分布

另一类常见的统计量是次序统计量。

一、定义 5.3.7 设 $x_1, x_2, \dots, x_n$ 是取自总体 X 的样本,

$x_{(i)}$ 称为该样本的第 i 个次序统计量, 它的取值是将样本观测值由小到大排列后得到的第 i 个

观测值。其中 $x_{(1)} = \min\{x_1, x_2, \dots, x_n\}$ 称为该样本

为的最小次序统计量, 称 $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$

为该样本的最大次序统计量。

我们知道，在一个样本中， $x_1, x_2, \dots, x_n$ 是独立同分布的，而次序统计量 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 则既不独立，分布也不相同，看下例。

例 5.3.6 设总体 X 的分布为仅取 0, 1, 2 的离散

均匀分布，分布列为

x	0	1	2
p	1/3	1/3	1/3

现从中抽取容量为 3 的样本，其一切可能取值有 $3^3=27$ 种，表 5.3.6 列出了这些值，由此

可给出的 $x_{(1)}, x_{(2)}, x_{(3)}$ 分布列如下:

$x_{(1)}$	0	1	2
p	$\frac{19}{27}$	$\frac{7}{27}$	$\frac{1}{27}$

$x_{(2)}$	0	1	2
p	$\frac{7}{27}$	$\frac{13}{27}$	$\frac{7}{27}$

$x_{(3)}$	0	1	2
p	$\frac{1}{27}$	$\frac{7}{27}$	$\frac{19}{27}$

我们可以清楚地看到这三个次序统计量的分布是不相同的。

进一步，我们可以给出两个次序统计量的联合分布，如， $x_{(1)}$ 和 $x_{(2)}$ 的联合分布列为

$x_{(1)} \quad x_{(2)}$	0	1	2
0	$7/27$	$9/27$	$3/27$
1	0	$4/27$	$3/27$
2	0	0	$1/27$

因为 $P(x_{(1)} = 0, x_{(2)} = 0) = 7/27$,

而

$$P(x_{(1)} = 0) * P(x_{(2)} = 0) = (19/27) * (7/27) ,$$

二者不等,

由此可看出 $x_{(1)}$ 和 $x_{(2)}$ 是不独立的。



二、单个次序统计量的分布

定理 5.3.5 设总体 X 的密度函数为 $p(x)$,
分布

函数为 $F(x)$, $x_1, x_2, \dots, x_n$ 为样本, 则

第 k 个
次序统计量 $x_{(k)}$ 的密度函数为

$$p_k(x) = \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} (1-F(x))^{n-k} p(x)$$

例 5.3.7 设总体密度函数为 $p(x)=3x^2, 0<x<1$.
从该总体抽得一个容量为 5 的
样本,

解: 有两种求法: 从古典概型出发; 从次序统计量密度函数出发。

例 5.3.8 设总体分布为 $U(0,1)$, $x_1, x_2, \dots, x_n$ 为
样
本, 试求第 k 个次序统计量

的分布



三、多个次序统计量的联合分布

对任意多个次序统计量可给出其联合分布，以两个为例说明：

定理 5.3.6 在定理 5.3.5 的记号下，次序统计

量 $(x_{(i)}, x_{(j)}), (i < j)$ 的联合分布密度函数为

$$p_{ij}(y, z) = \frac{(n-i-1)!(j-i-1)!(n-j)!}{(i-1)!(j-i-1)!(n-j)!} [F(y)]^{i-1} [F(z) - F(y)]^{j-i-1} \cdot [1 - F(z)]^{n-j} p(y)p(z), \quad y \leq z$$

次序统计量的函数在实际中经常用到。

如 样本极差 $R_n = x_{(n)} - x_{(1)}$,

样本中程 $[x_{(n)} - x_{(1)}] / 2$ 。

样本极差是一个很常用的统计量，其分布只在很少几种场合可用初等函数表示。

例 5.3.9 设总体分布为 $U(0,1)$, $x_1, x_2, \dots, x_n$ 为

样本, 则 $(x_{(n)}, x_{(1)})$ 的联合密度函数为

令 $R = x_{(n)} - x_{(1)}$, 由 $R > 0$, 可以推出

$$0 < x_{(1)} = x_{(n)} - R \leq 1 - R ,$$

则

$$p_R(r) = \int_0^{1-r} n(n-1)[(y+r)-y]^{n-2} dy = n(n-1)r^{n-2}(1-r)$$

这正是参数为 $(n-1, 2)$ 的贝塔分布。

5.3.6 样本分位数与样本中位数

样本中位数也是一个很常见的统计量，它也是次序统计量的函数，通常如下定义：

$$m_{0.5} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & n \text{ 为奇数} \\ \frac{1}{2} \left(x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)} \right), & n \text{ 为偶数} \end{cases}$$

更一般地，样本 p 分位数 m_p 可如下定义：

$$m_p = \begin{cases} x_{([np+1])}, & \text{若 } np \text{ 不是整数} \\ \frac{1}{2} (x_{(np)} + x_{(np+1)}), & \text{若 } np \text{ 是整数} \end{cases}$$



定理 5.3.7 设总体密度函数为 $p(x)$, x_p 为其 p 分

当 n 位数时样本 m_p 在 x_p 处连续且的渐近分布为

$$m_p \sim N\left(x_p, \frac{p(1-p)}{n \cdot p^2 x_p}\right)$$

特别, 对样本中位数, 当 $n \rightarrow \infty$ 时近似地有

$$m_{0.5} \sim N\left(x_{0.5}, \frac{1}{4n \cdot p^2 x_{0.5}}\right)$$

例 5.3.10 设总体为柯西分布, 密度函数为

$$p(x, \theta) = 1/[\pi(1+(x-\theta)^2)] \quad , \quad -\infty < x < +\infty$$

不难看出 θ 是该总体的中位数, 即 $x_{0.5} = \theta$ 。

设 $x_1, x_2, \dots, x_n$ 是来自该总体的样本, 当样本量 n 较大时, 样本中位数 $m_{0.5}$ 的渐近分布为

$$m_{0.5} \sim AN(\theta, \pi^2/4n) .$$

通常, 样本均值在概括数据方面具有一定的优势。但当数据中含有极端值时, 使用中位数比使用均值更好, 中位数的这种抗干扰性在统计中称为具有稳健性。

5.3.7 五数概括与箱线图

次序统计量的应用之一是五数概括与箱线图。在得到有序样本后，容易计算如下五个值：

最小观测值 $x_{\min} = x_{(1)}$ ，最大观测值 $x_{\max} = x_{(n)}$ ，

中位数 $m_{0.5}$ ，

第一四分位数 $Q_1 = m_{0.25}$ ，第三四分位数 $Q_3 =$

所谓五数概括就是指用这五个数：

$$x_{\min}, \quad Q_1, \quad m_{0.5}, \quad Q_3, \quad x_{\max}$$

来大致描述一批数据的轮廓。

§5.4 三大抽样分布

大家很快会看到，有很多统计推断是基于正态分布的假设的，以标准正态变量为基石而构造的三个著名统计量在实际中有广泛的应用，这是因为这三个统计量不仅有明确背景，而且其抽样分布的密度函数有明显表达式，它们被称为统计中的 “ 三大抽样分布 ” 。

5.4.1 χ^2 分布 (卡方分布)

定义 5.4.1 设 $X_1, X_2, \dots, X_n$ 独立同分布于标准

正态分布 $N(0,1)$, 则 $\chi^2 = X_1^2 + \dots + X_n^2$ 的分

布称


当随机变量 $\chi^2 \sim \chi^2(n)$ 时, 对给定 α 为自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$ ($0 < \alpha < 1$), 称满足 $P(\chi^2 \leq \chi_{1-\alpha}^2(n))$ 的 $\chi_{1-\alpha}^2(n)$ 是自由度为 $n-1$ 的卡方分布的 $1-\alpha$ 分位数.

分位数 $\chi_{1-\alpha}^2(n)$ 可以从附表 3 中查到.

该密度函数的图像
是一只取非负值的
偏态分布

$$E\chi^2 = n,$$

$$\text{Var}(\chi^2) = 2n$$





5.4.2 F 分布

定义 5.4.2 设 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$, X_1 与 X_2 独立,


则称 $F = (X_1/m)/(X_2/n)$ 的分布是自由度为 m 与

n

当随机变量 $F \sim F(m, n)$ 时, 对给定其中 $0 < \alpha < 1$, 称满足 $P(F \leq F_{1-\alpha}(m, n)) = 1 - \alpha$ 的 $F_{1-\alpha}(m, n)$ 是自由度为 m 与 n 的母分布的 $1 - \alpha$ 分位数。

由 F 分布的构造知 $F_{\alpha}(n, m) = 1/F_{1-\alpha}(m, n)$ 。

该密度函数的图象也是一只取非负值的偏态分布



5.4.3 t 分布


定义 5.4.3 设随机变量 X_1 与 X_2 独立,

且 $X_1 \sim N(0,1)$, $X_2 \sim \chi^2(n)$, 则称

$$t = X_1 / \sqrt{X_2/n}$$

的分布为自由度为 n 的 t 分布, 记为 $t \sim t(n)$ 。

t 分布的密度函数的图象是一个关于纵轴对称的分布，与标准正态分布的密度函数形状类似，只是峰比标准正态分布低一些尾部的概率比标准正态分布的大一些。



- 自由度为 1 的 t 分布就是标准柯西分布,
- 它的均值不存在; t 分布的数学期望存在且为 0 ;
- $n > 2$ 时, t 分布的方差存在, 且为 $n/(n-2)$;
- 当自由度较大 (如 $n \geq 30$) 时, t 分布可以用正态分布 $N(0,1)$ 近似。

当随机变量 $t \sim t(n)$ 时, 称满足

$$P(t \leq t_{1-\alpha}(n)) = 1 - \alpha$$

的 $t_{1-\alpha}(n)$ 是自由度为 n 的 t 分布的 $1-\alpha$ 分位数.
分位数 $t_{1-\alpha}(n)$ 可以从附表 4 中查到.

譬如 $n=10, \alpha=0.05$, 那么从附表 4 上查得

$$t_{1-0.05}(10) = t_{0.95}(10) = 1.812.$$

由于 t 分布的密度函数关于 0 对称, 故其分位数间有如下关系

$$t_{\alpha}(n-1) = -t_{1-\alpha}(n-1)$$

5.4.4 一些重要结论

定理 5.4.1 设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu, \sigma^2)$ 的

样本, 其样本均值和样本方差分别为 $\bar{x}$ 和 s^2 , 则有

- (1) $\bar{x}$ 与 s^2 相互独立;
- (2) $\bar{x} \sim N(\mu, \sigma^2/n)$;
- (3) $(n-1) s^2/\sigma^2 \sim \chi^2(n-1)$ 。

推论 5.4.3 设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu_1, \sigma_1^2)$

的

样本, $y_1, y_2, \dots, y_n$ 是来自 $N(\mu_2, \sigma_2^2)$ 的样

本,

$$F = \frac{s_x^2 / \sigma_1^2}{s_y^2 / \sigma_2^2} \sim F(m-1, n-1)$$

且此两样本相互独立, 则有

特别, 若 $\sigma_1^2 = \sigma_2^2$, 则

$$F = s_x^2 / s_y^2 \sim F(m-1, n-1)$$

推论 5.4.4 在推论 5.4.3 的记号下, 设

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

并记

$$s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2} = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - \bar{y})^2}{m+n-2}$$

则

$$\frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

§5.5 充分统计量

5.5.1 充分性的概念

例 5.5.1 为研究某个运动员的打靶命中率，我们对该运动员进行测试，观测其 10 次，发现除第

三、六次未命中外，其余 8 次都命中。这样的观测结果包含两种信息：

- (1) 打靶 10 次命中 8 次；
- (2) 2 次不命中分别出现在第 3 次和第 6 次打靶上。

第二种信息对了解该运动员的命中率是没有什么帮助的。一般地, 设我们对该运动员进行 n 次观测, 得到 $x_1, x_2, \dots, x_n$, 每个 x_j 取值非 0 即 1, 命中为 1, 不命中为 0。令 $T = x_1 + \dots + x_n$, T 为观测到的命中次数。在这种场合仅仅记录使用 T 不会丢失任何与命中率 θ 有关的信息, 统计上将这种“样本加工不损失信息”称为“充分性”。

样本 $x = (x_1, x_2, \dots, x_n)$ 有一个样本分布 $F_\theta(x)$, 这个分布包含了样本中一切有关 θ 的信息。

统计量 $T = T(x_1, x_2, \dots, x_n)$ 也有一个抽样分布 $F_\theta^T(t)$ ，当我们期望用统计量 T 代替原始样本并且不损失任何有关 θ 的信息时，也就是期望抽样分布 $F_\theta^T(t)$ 像 $F_\theta(x)$ 一样概括了有关 θ 的一切信息，这即是说在统计量

T 的取值为 t 的情况下样本 x 的条件分布

$F_\theta(x|T=t)$ 已不含 θ 的信息，这正是统计量具有充分性的含义。

定义 5.5.1 设 $x_1, x_2, \dots, x_n$ 是来自某个总体
的样本, 总体分布函数为 $F(x; \theta)$, 统计
量 $T = T(x_1, x_2, \dots, x_n)$ 称为 θ 的充分
统计量, 如果在给定 T 的取值后, $x_1, x_2, \dots,$
 x_n

的条件分布与 θ 无关.

5.5.2 因子分解定理

充分性原则：在统计学中有一个基本原则——

在充分统计量存在的场合，任何统计推断都

可以基于充分统计量进行。这可以简化统计推断的程序。

定理 5.5.1 设总体概率密度函数为 $p(x; \theta)$ ， $X_1, \dots, X_n$ 为样本，则 $T = T(X_1, \dots, X_n)$ 为充分统计量的充

分必要条件是：存在两个函数 $g(t; \theta)$ 和 $h(x_1, x_2, \dots, x_n)$ ，使得

$$p(x_1, x_2, \dots, x_n; \theta) = g(T(x_1, x_2, \dots, x_n); \theta) h(x_1, x_2, \dots, x_n) \quad (5.5.1)$$

使得对任意的 θ 和任一组观测值 $x_1, x_2, \dots, x_n$ ，

其中 $g(t, \theta)$ 是通过统计量 T 的取值而依赖于样本的。

例 5.5.4 设 $x_1, x_2, \dots, x_n$ 是取自总体 $U(0, \theta)$ 的样本,

$$\text{即总体的密度函数为, } 0 < x < \theta$$
$$p(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta \\ 0, & \text{其他} \end{cases}$$

于是样本的联合密度函数为

$$p(x_1; \theta) \dots p(x_n; \theta) = \begin{cases} (1/\theta)^n, & 0 < \min\{x_i\} < \max\{x_i\} < \theta \\ 0, & \text{其它} \end{cases}$$

由于诸 $x_i > 0$, 所以我们将上式改写为

$$p(x_1; \theta) \dots p(x_n; \theta) = (1/\theta)^n I_{\{x_{(n)}\} < \theta}$$

取 $T = x_{(n)}$, 并令 $g(t; \theta) = (1/\theta)^n I_{\{t < \theta\}}$, $h(x) = 1$,
由因子分解定理知 $T = x_{(n)}$ 是 θ 的充分统计量。

例 5.5.5 设 $x_1, x_2, \dots, x_n$ 是取自总体 $N(\mu, \sigma^2)$ 的样本, $\theta = (\mu, \sigma^2)$ 是未知的, 则联合密度函数为

$$\begin{aligned} p(x_1, \cdots, x_n; \theta) &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{n\mu^2}{2\sigma^2}\right\} \exp\left\{-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i\right)\right\} \end{aligned}$$

取 $t_1 = \sum x_i$, $t_2 = \sum x_i^2$, 并令

$$\begin{aligned} g(t_1, t_2, \theta) &= (2\pi\sigma^2)^{-n/2} \exp\{-n\mu^2/(2\sigma^2)\} \\ &\quad \times \exp\{(t_2 - 2\mu t_1)/(-2\sigma^2)\}, \end{aligned}$$

其中 $h(x)=1$,

由因子分解定理, $T=(\sum x_i, \sum x_i^2)$ 是充分统计量。

进一步, 我们指出这个统计量与 $(\bar{x}, s^2)$ 是一一对应的, 这说明在正态总体场合常用的 $(\bar{x}, s^2)$ 是充分统计量。