



§8.1 方差分析

8.1.1 问题的提出

实际工作中我们经常碰到多个正态总体均值的比较问题 处理这类问题通常采用所谓的方差分析方法。



例 8.1.1 在饲料养鸡增肥的研究中, 某研究所提出三种饲料配方: A_1 是以鱼粉为主的饲料, A_2 是以槐树粉为主的饲料, A_3 是以苜蓿粉为主的饲料。为比较三种饲料的效果, 特选 24 只相似的雏鸡随机均分为三组 每组各喂一种饲料, 60 天后观察它们的重量。试验结果如下表所示:

表 8.1.1 鸡饲料试验数据

饲料 A	鸡 重 (克)							
A_1	1073	1009	1060	1001	1002	1012	1009	1028
A_2	1107	1092	990	1109	1090	1074	1122	1001
A_3	1093	1029	1080	1021	1022	1032	1029	1048



本例中，我们要比较的是三种饲料对鸡的增肥作用是否相同。为此，把饲料称为因子，记为 A ，三种不同的配方称为因子 A 的三个水平，记为 A_1, A_2, A_3 ，使用配方 A_i 下第 j 只鸡 60 天后的重量用 y_{ij} 表示， $i=1, 2, 3, j=1, 2, \dots, 10$ 。我们的目的是比较三种饲料配方下鸡的平均重量是否相等，为此，需要做一些基本假定，把所研究的问题作为一个统计问题，然后用方差分析的方法进行解决。



8.1.2 单因子方差分析的统计模型

在例 8.1.1 中我们只考察了一个因子，称其为因子试验

通常，在单因子试验中，因子为 A ，设有 r 个水平，记为 $A_1, A_2, \dots, A_r$ ，在每一水平下考察的指标可以看成是一个总体，现有 r 个水平，故有 r 个总体，假定：

- 1) 每一总体均为正态体, 记为 $N(\mu_i, \sigma_i^2)$, $i = 1, 2, \dots, r$;
- 2) 各总体的方差相同: $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_r^2 = \sigma^2$;
- 3) 从每一总体中抽取的样本是相互独立的, 即所有的试验结果 y_{ij} 都相互独立。



我们要比较各水平下的均值是否相同，
即要对如下的一个假设进行检验

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_r \quad (8.1.)$$

1)

备择假设

$$H_1 : \mu_1, \mu_2, \dots, \mu_r \text{ 不全相等}$$

在不会引起误解的情况下， H_1 通常可省略不写。

如果 H_0 成立，因子 A 的 r 个水平均值相同，称因子 A 的 r 个水平间没有显著差异，简称因子 A **不显著**；反之，当 H_0 不成立时 因子 A 的 r 个水平均值不全相同，速称因子 A 的不同水平间有显著差异，简称因子 A **显著**。



为假设 (8.1.1) 进行检验 需要从每一水平下的总体抽取样本, 设从第 i 个水平下的总体获得 m 个试验结果, 记 y_{ij} 表示第 i 个总体的第 j 次重复试验结果。共得如下 $n=r \times m$ 个试验结果:

$$y_{ij}, \quad i = 1, 2, \dots, r, \quad j = 1, 2, \dots, m,$$

其中 r 为水平数, m 为重复数, i 为水平编号,

j 为重复编号。

在水平 A_i 下的试验结果 y_{ij} 与该水平下的指标均值 μ_i 一般总是有差距的, 记 $\varepsilon_{ij} = y_{ij} - \mu_i$, ε_{ij} 称为随机误差。于是有

$$y_{ij} = \mu_i + \varepsilon_{ij} \quad (8.1.2)$$

(8.1.2) 式称为试验结果 y_{ij} 的数据结构式。

单因子方差分析的统计模型:

$$\begin{cases} y_{ij} = \mu_i + \varepsilon_{ij}, i = 1, 2, \dots, r, j = 1, 2, \dots, m \\ \text{诸 } \varepsilon_{ij} \text{ 相互独立, (且都服从 } N(0, \sigma^2) \end{cases}$$

总均值与效应:

称诸 μ_i 的平均
为总均值. $\mu = \frac{1}{r}(\mu_1 + \dots + \mu_r) = \frac{1}{r} \sum_{i=1}^r \mu_i$

称第 i 水平下的均值 μ_i 与总均值 μ 的差:
 $a_i = \mu_i - \mu$ 为 A_i 的效应。

模型 (8.1.3) 可以改写为

$$\left\{ \begin{array}{l} y_{ij} = \mu + a_i + \varepsilon_{ij}, \quad i = 1, 2, \dots, r, j = 1, 2, \dots, m \\ \sum_{i=1}^r a_i = 0 \\ \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2) \end{array} \right. \quad (8.1.8)$$

假设 (8.1.1) 可改写为

$$H_0 : a_1 = a_2 = \dots = a_r = 0 \quad (8.1.9)$$

8.1.3 平方和分解

一、试验数据

通常在单因子方差分析中可将试验数据列成如下表格形式。

表 8.1.2 中的最后二列的和与平均的含义如下：

$$T_i = \sum_{j=1}^m y_{ij} \quad \bar{y}_i = \frac{T_i}{m} \quad i = 1, 2, \dots, r$$

$$T = \sum_{i=1}^r T_i \quad \bar{y} = \frac{T}{r \cdot m} = \frac{T}{n}$$

$$n = r \cdot m = \text{总试验次数}$$



表 8.1.2 单因子方差分析试验数据

因子水平	试 验 数 据	和	平均
A_1	$y_{11} \ y_{12} \ \cdots \ y_{1m}$	T_1	$\bar{y}_1$
A_2	$y_{21} \ y_{22} \ \cdots \ y_{2m}$	T_2	$\bar{y}_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
A_r	$y_{r1} \ y_{r2} \ \cdots \ y_{rm}$	T_r	$\bar{y}_r$
		T	$\bar{y}$

二、组内偏差与组间偏差

数据间是有差异的。数据 y_{ij} 与总平均 $\bar{y}$ 间的偏差可用 $y_{ij} - \bar{y}$ 表示, 它可分解为二个偏差之和

$$y_{ij} - \bar{y} = (y_{ij} - \bar{y}_{i.}) + (\bar{y}_{i.} - \bar{y})$$

(8.1.10)

$$\bar{\varepsilon}_{i.} = \frac{1}{m} \sum_{j=1}^m \varepsilon_{ij}, \quad \bar{\varepsilon} = \frac{1}{r} \sum_{i=1}^r \bar{\varepsilon}_{i.} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^m \varepsilon_{ij}$$

由于

$$y_{ij} - \bar{y}_i = (\mu_i + \varepsilon_{ij}) - (\mu_i + \bar{\varepsilon}_i) = \varepsilon_{ij} - \bar{\varepsilon}_i \quad (8.1.11)$$

所以 $y_{ij} - \bar{y}_i$ 仅反映组内数据与组内平均的随机误差, 称为**组内偏差**; 而

$$\bar{y}_i - \bar{y} = (\mu_i + \bar{\varepsilon}_i) - (\mu + \bar{\varepsilon}) = \mu_i - \mu + \bar{\varepsilon}_i - \bar{\varepsilon} \quad (8.1.12)$$

除了反映随机误差外, 还反映了第 i 个水平的效应 称为**组间偏差**。

三、偏差平方和及其自由度

- 在统计学中, 把 k 个数据 $y_1, y_2, \dots, y_k$ 分别对其均值 $\bar{y} = (y_1 + \dots + y_k)/k$ 的偏差平方和

$$Q = (y_1 - \bar{y})^2 + \dots + (y_k - \bar{y})^2 = \sum_{i=1}^k (y_i - \bar{y})^2$$

称为 k 个数据的偏差平方和, 它常用来度量若干个数据分散的程度。

- 在构成偏差平方和 Q 的 k 个偏差 $y_1 - \bar{y}, \dots, y_k - \bar{y}$ 间有一个恒等式 $\sum_{i=1}^k (y_i - \bar{y}) = 0$ ，这说明在 Q 中独立的偏差只有 $k-1$ 个。
- 在统学中把平方和中独立偏差个数称为平方和的**自由度**，常记为 f ，如 Q 的自由度为 $f_Q = k-1$ 。自由度是偏差平方和的一个重要参数。

四、总平方和分解公式

- 各 y_{ij} 间的差异大小可用总偏差平方和

$$S_T = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y})^2$$

表示，其自由度为 $f_T = n - 1$ ；

- 仅由随机误差引起的数据间的差异可以用

组内偏差平方和 $S_e = \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})^2$

表示，

也称为误差偏差平方和，其自由度为 $f_e = n - r$

- 由于组内差异除了随机误差外，还反映了效应间的差异，故由效应不同引起的数据差异可用

组内偏差平方和

$$S_A = m \sum_{i=1}^r (\bar{y}_{i.} - \bar{y})^2$$

表示，也称为因子 A 的偏差平方和，其自由度为 $f_A = r - 1$ ；

定理 8.1.1 在上述符号下, 总平方和 S_T 可以分解为因子平方和 S_A 与误差平方和 S_e 之和, 其自由度也有相应分解公式, 具体为

$$S_T = S_A + S_e, \quad f_T = f_A + f_e \quad (8.1.16)$$

(8.1.16) 式通常称为**总平方和分解式**。

8.1.4 检验方法

偏差平方和 Q 的大小与自由度有关, 为了便于在偏差平方和之间进行比较, 统计上引入了均方和的概念, 它定义为 $MS = Q/f_Q$, 其意为平均每个自由度上有多少平方和, 它比较好地度量了一组数据的离散程度。

如今要对因子平方和 S_A 与误差平方和 S_e 之间进行比较, 用其均方和 $MS_A = S_A / f_A$, $MS_e = S_e / f_e$ 进行比较更为合理, 故可用

作为检验 H_0 的统量。
$$F = \frac{MS_A}{MS_e} = \frac{S_A / f_A}{S_e / f_e}$$

定理 8.1.2 在单因子方差分析模型 (8.1.8) 及前述符号下, 有

(1) $S_e/\sigma^2 \sim \chi^2(n-r)$, 从而 $E(S_e) = (n-r) \sigma^2$

$$E(S_A) = (r-1)\sigma^2 + m \sum_{i=1}^r a_i^2$$

, 进一步, 若 H_0 成

立, 则有 $S_A/\sigma^2 \sim \chi^2(r-1)$

(2) S_A 与 S_e 独立。

由定理 8.1.2 , 若 H_0 成立, 则检验统计量 F 服从自由度为 f_A 和 f_e 的 F 分布, 因此拒绝域为 $W=\{F \geq F_{1-\alpha}(f_A, f_e)\}$, 通常将上述计算过程列成一张表格, 称为方差分析表。表 8.1.3 单因子方差分析表

来源	平方和	自由度	均方和	F 比
因子	S_A	$f_A=r-1$	$MS_A = S_A/f_A$	$F = MS_A / MS_e$
误差	S_e	$f_e=n-r$	$MS_e = S_e/f_e$	
总和	S_T	$f_T=n-1$		

对给定的 α , 可作如下判断:

- 如果 $F > F_{1-\alpha}(f_A, f_e)$, 则认为因子 A 显著;
- 若 $F \leq F_{1-\alpha}(f_A, f_e)$, 则说明因子 A 不显著。

该检验的 p 值也可利用统计软件求出,
若

以 Y 记服从 $F(f_A, f_e)$ 的随机变量, 则检
验的

p 值为 $p = P(Y \geq F)$ 。

常用的各偏差平方和的计算公式如下：

$$S_T = \sum_{i=1}^r \sum_{j=1}^m y_{ij}^2 - \frac{T^2}{n}$$

$$S_A = \frac{1}{m} \sum_{i=1}^r T_i^2 - \frac{T^2}{n} \quad (8.1.19)$$

$$S_e = S_T - S_A$$

一般可将计算过程列表进行。

例 8.1.2 采用例 8.1.1 的数据，将原始数据减去 1000，列表给出计算过程：

表 8.1.4 例 8.1.2 的计算表

水平	数据 (原始数据 - 1000)								T_i	T_i^2	$\sum_{j=1}^m y_{ij}^2$
A_1	73	9	60	1	2	12	9	28	194	37636	10024
A_2	107	92	-10	109	90	74	122	1	585	342225	60355
A_3	93	29	80	21	22	32	29	48	354	125316	20984
									1133	505177	91363

利用 (8.1.19), 可算得各偏差平方和为

$$S_T = 91363 - \frac{1133^2}{24} = 37876.0417, \quad f_T = 24 - 1 = 23$$

$$S_A = \frac{505177}{8} - \frac{1133^2}{24} = 9660.0833, \quad f_A = 3 - 1 = 2$$

$$S_e = S_T - S_A = 37876.0417 - 9660.0833 = 28215.9584, \quad f_e = 3(8 - 1) = 21$$

把上述诸平方和及其自由度填入方差分析表

表 8.1.5 例 8.1.2 的方差分析表

来源	平方和	自由度	均方和	F 比
因子	9660.0833	2	4830.0417	3.5948
误差	28215.9584	21	1343.6171	
总和	37876.0417	23		

若取 $\alpha=0.05$, 则 $F_{0.95}(2,21)=3.47$, 由于 $F=3.5948>3.47$, 故认为因子 A (饲料) 是显著的, 即三种饲料对鸡的增肥作用有明显的差别。

8.1.5 参数估计

在检验结果为显著时 我们可进一步求出总均值、
各主效应 α_i 和误差方差 σ^2 的估计

一、点估计

由模型 (8.1.8) 知诸 y_{ij} 相互独立, 且 $y_{ij} \sim N(\mu + a_i, \sigma^2)$, 因此,

可使用极大似然方法求出一般平均 μ 、各主效应 a_i 和误差方

差 σ^2 的估计:

$$\hat{a}_i = \bar{y}_{i.} - \bar{y}, \quad i = 1, \dots, r$$

$$\hat{\sigma}_M^2 = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^m (y_{ij} - \bar{y})^2 = \frac{S_e}{n}$$

$$\hat{\mu}_i = \bar{y}_{i.}$$

$$\hat{\sigma}_M^2$$

$$\hat{\sigma}^2 = MS_e$$

由极大似然估计的不变性, 各水平均值 μ_i 的极大似然估计

为 $\bar{y}_{i.}$, 由于 $\hat{\sigma}_M^2$ 不是 σ^2 的无偏估计

April 8, 2026

, 由于

不是 σ^2 的无偏估计

二、置信区间

由于 $\frac{\sqrt{m}(\bar{y}_{i.} - \mu_i)}{\sqrt{S_e / f_e}} \sim t(f_e)$, 可给出

A_i 的水平均值 μ_i 的 $1-\alpha$ 的置信区间为

$$\left[\bar{y}_{i.} - \hat{\sigma} \cdot t_{1-\alpha/2}(f_e) / \sqrt{m}, \quad \bar{y}_{i.} + \hat{\sigma} \cdot t_{1-\alpha/2}(f_e) / \sqrt{m} \right]$$

$$\hat{\sigma}^2 = MS_e$$

其中 $t_{1-\alpha/2}(f_e)$ 为自由度为 f_e 的 t 分布的上 $1-\alpha/2$ 分位数。



例 8.1.3 继续例 8.1.2, 此处我们给出诸水平平均值的估计 因子 A 的三个水平平均值的估计分别为

$$\hat{\mu}_1 = 1000 + \frac{194}{8} = 1024.25,$$

$$\hat{\mu}_2 = 1000 + \frac{585}{8} = 1073.125,$$

从点估计来看, 水平 2 ($1000 + \frac{354}{8} = 1044.25$, 以槐树粉为主的饲料) 是最优的。

误差方差的无偏估计为

$$\hat{\sigma}^2 = MS_e = 1343.6171$$

利用 (8.1.23) 可以给出诸水平平均值的置信区间

此处 $\hat{\sigma} = \sqrt{1343.6171} = 36.6554$

若取 $\alpha = 0.05$, 则 $t_{1-\alpha/2}(f_e) = t_{0.975}(22) = 2.0796$

, 于是三个水平平均值的 $1-\alpha=0.95$ 置信区间分别为

$$\mu_1 : 1044.25 \pm 26.9509 = [1017.2891, 1071.2109],$$

$$\mu_2 : 1073.125 \pm 26.9509 = [1046.1741, 1100.0759],$$

$$\mu_3 : 1044.25 \pm 26.9509 = [1017.2891, 1071.2109].$$

在单因子试验的数据分析中可得到如下三个结果：

- 因子是否显著；
- 试验的误差方差 σ^2 的估计；
- 诸水平均值 μ_i 的点估计与区间估计。

在因子 A 显著时，通常只需对较优的水平均值作参数估计，在因子 A 不显著场合，参数估计无需进行。

8.1.6 重复数不等情形

单因子方差分析并不要求每个水平下重复试验次数全相等，在重复数不等场合的方差分析与重复数相等情况下的方差分析极为相似，只在几处略有差别

- 数据：设从第 i 个水平下的总体获得 m_i 个试验结果，记为 $y_{i1}, y_{i2}, \dots, y_{im_i}$ ， $i=1, 2, \dots, r$ ，统计模型为：

$$\begin{cases} y_{ij} = \mu_i + \varepsilon_{ij}, & i = 1, 2, \dots, r, & j = 1, 2, \dots, m_i \\ \text{各 } \varepsilon_{ij} \text{ 相互独立, 且都服从 } N(0, \sigma^2) \end{cases}$$

(8.1.24)

- 总均值 μ 是 μ_i 的加权平均 (所有试验结果的均值的平均)

$$\mu = \frac{1}{n} (m_1 \mu_1 + \dots + m_r \mu_r) = \frac{1}{n} \sum_{i=1}^r m_i \mu_i \quad (8.1.25)$$

称为均值或一般平均。

- 效应约束条件: $\sum_{i=1}^r m_i a_i = 0$

- 各平方和的计算: S_A 的计算公式略有不同

$$S_A = \sum_{i=1}^r m_i (\bar{y}_i - \bar{y})^2 = \sum_{i=1}^r \frac{T_i^2}{m_i} - \frac{T^2}{n}$$

例 8.1.4 某食品公司对一种食品设计了四种新包装。为考察哪种包装最受顾客欢迎，选了 10 个地段繁华程度相似、规模相近的商店做试验。其中二种包装各指定两个商店销售，另二个包装各指定三个商店销售。在试验期内各店货架排放的位置、空间都相同，营业的促销方法也基本相同，经过一段时间记录其销售量数据，列于表 8.1.6 左半边。其相应的计算结果列于右侧。



表 8.1.6 销售量数据及计算表

包装 类型	销售量			m_i	T_i	T_i^2 / m_i	$\sum_{j=1}^{m_i} y_{ij}^2$
A_1	12	18		2	30	450	468
A_2	14	12	13	3	39	507	509
A_3	19	17	21	3	57	1083	1091
A_4	24	30		2	54	1458	1476
和				$n=10$	$T=180$	$\sum_{i=1}^r \frac{T_i^2}{m_i} = 3498$	$\sum_{i=1}^r \sum_{j=1}^{m_i} y_{ij}^2 = 3544$

由此可求得各类偏差平方和如下 $\left(\frac{T^2}{n} = \frac{180^2}{10} = 3240 \right)$

$$S_T = 3544 - 3240 = 304, \quad f_T = 10 - 1 = 9$$

$$S_A = 3498 - 3240 = 258, \quad f_A = 4 - 1 = 3$$

$$S_e = 304 - 258 = 46, \quad f_e = 10 - 4 = 6$$

方差分析表如表 8.1.8 所示 .

若取 $\alpha = 0.01$, 查表得 $F_{0.01}(3,6)=9.78$, 由于 $F=11.22>9.78$, 故我们可认为各水平间有显著差异。

表 8.1.7 例 8.1.4 的方差分析表

来源	平方和	自由度	均方和	F 比
因子 A	258	3	86	11.22
误差 e	46	6	7.67	
总和 T	304	9		

由于因子显著，我们还可以给出诸水平平均值的估计。因子 A 的四个水平平均值的估计分别为

$$\hat{\mu}_1 = 30/2 = 15, \quad \hat{\mu}_2 = 39/3 = 13,$$

由此可见 $\hat{\mu}_3 = 57/3 = 19$, $\hat{\mu}_4 = 54/3 = 18$ 第四种包装方式效果最好。误差方差的无偏估计为

$$\hat{\sigma}^2 = MS_e = 7.67$$

进一步, 利用 (8.1.23) 也可以给出诸水平平均值的置信区间 只是在这里要用不同的 m_i 代替那里相同的 m 。此处 $\hat{\sigma} = \sqrt{7.67} = 2.7695$, 若取 $\alpha = 0.05$, 则 $t_{1-\alpha/2}(f_e) = t_{0.95}(6) = 2.4469$, $\hat{\sigma} t_{0.95}(6) = 6.7767$, 于是效果较好的第三和第四个水平平均值的 0.95 置信区间分别为

$$\mu_3 : 19 \pm 6.7767 / \sqrt{3} = [15.0875, 22.9125],$$

$$\mu_4 : 27 \pm 6.7767 / \sqrt{2} = [22.2081, 31.7919].$$

§8.2 多重比较

8.2.1 效应差的置信区间

如果方差分析的结果因子 A 显著, 则等于说有充分理由认为因子 A 各水平的效应不全相同, 但这并不是说它们中一定没有相同的。就指定的一对水平 A_i 与 A_j , 我们可通过求 $\mu_i - \mu_j$ 的区间估计来进行比较

由于 $\bar{y}_i - \bar{y}_j \sim N(\mu_i - \mu_j, (\frac{1}{m_i} + \frac{1}{m_j})\sigma^2)$

, 故
$$\frac{(\bar{y}_i - \bar{y}_j) - (\mu_i - \mu_j)}{\sqrt{(\frac{1}{m_i} + \frac{1}{m_j}) \frac{S_e}{f_e}}} \sim t(f_e)$$

由此给出 $\mu_1 - \mu_j$ 的置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\bar{y}_i - \bar{y}_j - \sqrt{(\frac{1}{m_i} + \frac{1}{m_j}) \hat{\sigma}^2} \cdot t_{1-\frac{\alpha}{2}}(f_e), \bar{y}_i - \bar{y}_j + \sqrt{(\frac{1}{m_i} + \frac{1}{m_j}) \hat{\sigma}^2} \cdot t_{1-\frac{\alpha}{2}}(f_e) \right] \quad (8.2.1)$$

其中 $\hat{\sigma}^2 = S_e / f_e$ 是 σ^2 的无偏估计

这里的置信区间与第六章中的两样本的 t 区间基本一致, 区别在于这里 σ^2 的估计使用了全部样本而不仅仅是两个水平 A_i, A_j 下的观测值。

例 8.2.1 继续例 8.1.2 , $\hat{\sigma} = \sqrt{1343.6171} = 36.6554$
 , $f_e = 21$, 取 $\alpha = 0.05$, 则 $t_{1-\alpha/2}(f_e) = t_{0.975}(21) = 2.0796$,
 $\sqrt{\frac{1}{8} + \frac{1}{8}} \hat{\sigma} t_{0.975}(21) = 38.1143$

于是可算出各个置信区间为

$$\mu_1 - \mu_2 : -48.8750 \pm 38.1143 = [-86.9893, -10.7607]$$

$$\mu_1 - \mu_3 : -20 \pm 38.1143 = [-58.1143, 18.1143]$$

$$\mu_2 - \mu_3 : 28.8750 \pm 38.1143 = [-9.2393, 66.9893]$$

可见第一个区间在 0 的左边 所以我们可以概率 95% 断言认为 μ_1 小于 μ_2 , 其它二个区间包含 0 点, 虽然从点估计角度看水平均值估计有差别 但这种差异在 0.05 水平上是不显著的。

8.2.2 多重比较问题

对每一组 (i, j) , (8.2.1) 给出的区间的置信水平都是 $1-\alpha$, 但对多个这样的区间要求其同时成立, 其联合置信水平就不再是 $1-\alpha$ 了。

譬如, 设 $E_1, \dots, E_k$ 是 k 个随机事件, 且有 $P(E_i) = 1 - \alpha$, $i = 1, \dots, k$, 则其同时发生的概率

$$P\left(\bigcap_{i=1}^k E_i\right) = 1 - P\left(\bigcup_{i=1}^k \bar{E}_i\right) \geq 1 - \sum_{i=1}^k P(\bar{E}_i) = 1 - k\alpha$$

这说明它们同时发生的概率可能比 $1 - \alpha$ 小很多。

为了使它们同时发生的概率不低于 $1 - \alpha$, 一个办法是把每个事件发生的概率提高到 $1 - \alpha/k$. 这将导致每个置信区间很长, 联合置信区间的精度很差, 一般人们不采用这种方法。

在方差分析中, 如果经 F 检验拒绝原假设 表明因子 A 是显著的, 即 r 个水平对应的水平均值不全相等, 此时 我们还需要进一步确认哪些水平均值是确有差异的, 哪些水平均值无显著差异。

同时比较任意两个水平均值有无明显差异的问题称为多重比较 多重比较要以显著性水平 α 同时检验如下 $r(r-1)/2$ 个假设

$$H_0^{ij} : \mu_i = \mu_j, \quad 1 \leq (i, j) \leq r$$

直观地看, 当 H_0^{ij} 成立时 $|\bar{y}_i - \bar{y}_j|$ 不应过大, 因此, 关于假设(8.2.2) 的拒绝域应有如下形式

$$W = \bigcup_{1 \leq i < j \leq r} \{|\bar{y}_i - \bar{y}_j| \geq c_{ij}\}$$

诸界值在 (8.2.2) 成立时由 $P(W) = \alpha$ 确定。下面分重复数相等和不等分别介绍界值的确定。

8.2.3 重复数相等场合的 T 法

在重复数相等时 由对称性自然可以要求诸 c_{ij} 相等, 记为 c . 记 $\hat{\sigma}^2 = S_e / f_e$, 则由给定条件不难有

$$t_i = \frac{\bar{y}_{i.} - \mu_i}{\hat{\sigma} / \sqrt{m}} \sim t(f_e)$$



于是当 (8.2.2) 成立时 $\mu_1 = \dots = \mu_r = \mu$, 可推出

$$P(W) = P\left(q(r, f_e) \geq \sqrt{mc} / \hat{\sigma}\right)$$

其中 $q(r, f_e) = \max_i \frac{(\bar{y}_{i.} - \mu)}{\hat{\sigma} / \sqrt{m}} - \min_j \frac{(\bar{y}_{j.} - \mu)}{\hat{\sigma} / \sqrt{m}}$, 称为化极差统量, 其分布可由随机模拟方法得到。

于是 $c = q_{1-\alpha}(r, f_e) \hat{\sigma} / \sqrt{m}$, 其中 $q_{1-\alpha}(r, f_e)$ 表示 $q(r, f_e)$ 的 $1-\alpha$ 分位数, 其值在附表 8 中给出。

重复数相同时多重比较可总结如下：对给定的显著性水平 α ，查多重比较的分位数 $q(r, f_e)$ 表，计算

$$c = q_{1-\alpha}(r, f_e) \hat{\sigma} / \sqrt{m}$$

与 c 的大小，若

$$|\bar{y}_{i.} - \bar{y}_{j.}| \geq c$$

则为水平 A_i 与水平 A_j 间有显著差异，反之，则为水平 A_i 与水平 A_j 间无明显差别。这一方法最早由 T. urkey 提出，因此称为 T 法。



例 8.2.2 继续例 8.1.2, 若取 $\alpha = 0.05$, 则查表知 $q_{1-0.05}(3, 21) = 3.57$, 而

$$\hat{\sigma} = 36.6554 \quad \text{所以}$$

$$c = 3.57 \times 36.6554 / \sqrt{8} = 46.2659$$

, 认为

μ_1 与 μ_3 有显著差别 $|\bar{y}_1 - \bar{y}_3|$

$$|\bar{y}_1 - \bar{y}_3| = 20 < 46.2659$$

, 认为 μ_1 与 μ_3

无显著差别

$$|\bar{y}_2 - \bar{y}_3| = 46.875 > 46.2659$$

, 认为 μ_2

与 μ_3 有显著差别

这说明: μ_1 与 μ_3 之间无显著差别, 而它们与 μ_2 之间都有显著差异。

8.2.4 重复数不等场合的 S 法

在重复数不等时 若假设 (8.2.2) 成立, 则

$$t_{ij} = \frac{(\bar{y}_{i.} - \bar{y}_{j.})}{\sqrt{\frac{1}{m_i} + \frac{1}{m_j}} \hat{\sigma}} \sim t(f_e) \quad F_{ij} = \frac{(\bar{y}_{i.} - \bar{y}_{j.})^2}{(\frac{1}{m_i} + \frac{1}{m_j}) \hat{\sigma}^2} \sim F(1, f_e) \quad \text{或}$$

从而可以要求 $c_{ij} = c \sqrt{\frac{1}{m_i} + \frac{1}{m_j}}$, 在此要求下可推出

$$P(W) = P(\max_{1 \leq i < j \leq r} F_{ij} \geq (c / \hat{\sigma})^2)$$

可以证明 $\frac{\max_{1 \leq i < j \leq r} F_{ij}}{r-1} \sim F(r-1, f_e)$

$$(c/\hat{\sigma})^2 = \frac{F_{1-\alpha}(r-1, f_e)}{r-1}$$

从而
亦即

$$c_{ij} = \sqrt{(r-1)F_{1-\alpha}(r-1, f_e)\left(\frac{1}{m_i} + \frac{1}{m_j}\right)\hat{\sigma}^2}$$

例 8.2.3 在例 8.1.4 中, 我们指出包装方式对食品销量有明显的影响, 此处 $r=4, f_e=6, \hat{\sigma}^2=7.67$ 若取 $\alpha=0.05$, 则 $F_{0.95}(3,6)=4.76$ 。注意到 $m_1=m_4=2$, $m_2=m_3=3$, 故

$$c_{12} = c_{13} = c_{24} = c_{34} = \sqrt{3 \times 4.76 \times (1/2 + 1/3) \times 7.67} = 9.6$$

$$c_{14} = \sqrt{3 \times 4.76 \times (1/2 + 1/2) \times 7.67} = 10.5$$

$$c_{23} = \sqrt{3 \times 4.76 \times (1/3 + 1/3) \times 7.67} = 8.5$$

由于

$$|\bar{y}_{1.} - \bar{y}_{2.}| = 2 < c_{12}, |\bar{y}_{1.} - \bar{y}_{3.}| = 4 < c_{13}, |\bar{y}_{1.} - \bar{y}_{4.}| = 12 > c_{14}$$

$$|\bar{y}_{2.} - \bar{y}_{3.}| = 6 < c_{23}, |\bar{y}_{2.} - \bar{y}_{4.}| = 14 > c_{24}, |\bar{y}_{3.} - \bar{y}_{4.}| = 8 < c_{34}$$

说明 A_1, A_2, A_3 间无显著差异, A_1, A_2 与 A_4 有显著差异, 但 A_4 与 A_3 的差异却尚未达到显著水平。综上所述, 包装 A_4 销售量最佳。

§8.3 方差齐性检验

在进行方差分析时要求 r 个方差相等，称为方差齐性。理论研究表明，当正态性假定不满足时 F 检验影响较小，即 F 检验对正态性的偏离具有一定的稳健性，而 F 检验对方差齐性的偏离较敏感。所以 r 个方差的齐性检验就显得十分必要。

所谓方差齐性检验是对如下一对假设作出检验

$$H_0: \sigma_1^2 = \sigma_2^2 = \cdots \sigma_r^2 \quad \text{vs} \quad H_1: \text{诸 } \sigma_i^2 \text{ 不全相等} \\ (8.3.1)$$

很多统学家提出了一些很好的检验方法，这里介绍几个最常用的检验 它们是：

- Hartley 检验，仅适用于样本量相等的场合；
- Bartlett 检验，可用于样本量相等或不等的场合，但是每个样本量不得低于 5；
- 修正的 Bartlett 检验，在样本量较小或较大、相等或不等场合均可使用。

8.3.1 Hartley 检验

当各水平下试验重复次数相等时 即

$m_1=m_2=\dots=m_r=m$, Hartley 提出检验方差相等的检验统计量:

$$H = \frac{\max \{s_1^2, s_2^2, \dots, s_r^2\}}{\min \{s_1^2, s_2^2, \dots, s_r^2\}}$$

(8.3.2)

这个统计量的分布无明显的表达式, 但在诸方差相等条件下, 可通过随机模拟方法获得 H 分布的分位数, 该分布依赖于水平数 r 和样本方差的自由度 $f=m-1$, 因此该分布可记为 $H(r, f)$, 其分位数表列于附表 10 上。

直观上看, 当 H_0 成立, 即诸方差相等 ($\sigma_1^2 = \sigma_2^2 = \dots = \sigma_r^2$) 时 H 的值接近于 1, 当 H 的值较大时 诸方差间的差异就大, H 愈大, 诸方差间的差异就愈大, 这时拒绝 (8.3.1) 中的 H_0 。由此可知, 对给定的显著性水平 α , 检验 H_0 的拒绝域为

$$W = \{H > H_{1-\alpha}(r, f)\} \quad (8.3.$$

3)

其中 $H_{1-\alpha}(r, f)$ 为 H 分布的 $1-\alpha$ 分位数。

例 8.3.1 有四种不同牌号的铁锈防挤剂(简称防锈剂)，要比较其防锈能力。数据见表 8.3.1。

这是一个重复次数相等的单因子试验 我们考虑用方差分析方法对之进行比较分析，为此，首先要进行方差齐性检验

本例中，四个样本方差可由表 8.3.1 中诸 Q_i 求出，即

$$s_1^2 = \frac{81.00}{9} = 9.00, \quad s_2^2 = \frac{44.28}{9} = 4.92,$$

$$s_3^2 = \frac{42.33}{9} = 4.70, \quad s_4^2 = \frac{53.42}{9} = 5.94$$

由此可得统量 H 的值 $H = \frac{9.00}{4.70} = 1.9149$

在 $\alpha = 0.05$ 时 由附表 10 查得 $H_{0.95}(4, 9) = 6.31$ ，由于 $H < 6.31$ ，所以应保留原假设 H_0 ，即四个总体方差间无显著差异。

8.3.2 Bartlett 检验

在单因子方差分析中有 r 个样本, 设第 i 个样本方差为

$$s_i^2 = \frac{1}{m_i - 1} \sum_{j=1}^{m_i} (y_{ij} - \bar{y}_i)^2 = \frac{Q_i}{f_i}, \quad i = 1, 2, \dots, r$$

由于几何平均数总不会超过算术平均数, 故有 $GMS_e \leq MS_e$, 其中

$$MS_e = \frac{1}{f_e} \sum_{i=1}^r Q_i = \sum_{i=1}^r \frac{f_i}{f_e} s_i^2, \quad GMS_e = \left[(s_1^2)^{f_1} (s_2^2)^{f_2} \cdots (s_r^2)^{f_r} \right]^{1/f_e}$$

等号成立当且仅当诸 s_i^2 彼此相等, 若诸 s_i^2 间的差异愈大, 则此两个平均值之差也愈大。

由此可见 在比值 GMS_e/MS_e 较大时 就意味着样本方差差异较大, 从而检验 (8.3.1) 表示的一对假设的拒绝域是

$$W = \{ \ln GMS_e / MS_e > d \} \quad (8.3.4)$$

Bartlett 证明了, 检验的拒绝域为

$$W = \{ B > \chi_{1-\alpha}^2(r-1) \} \quad (8.3.8)$$

考虑到这里 χ^2 分布是近似分布, 在样本量 m_i 均不小于 5 时使用上述检验是适当的。

例 8.3.2 为研究各产地的绿茶的叶酸含量是否有显著差异，特选四个产地绿茶，其中 A_1 制作了 7 个样品， A_2 制作了 5 个样品， A_3 与 A_4 各制作了 6 个样品，共有 24 个样品，按随机次序测试其叶酸含量，测试结果如表 8.3.3 所示。



为能进行方差分析，首先要进行方差齐性检验 从表 8.3.3 中数据可求得 $s_1^2=2.14, s_2^2=2.83, s_3^2=2.41, s_4^2=1.12$ ，再从表 8.3.4 上查得 $MS_e=2.09$ ，由 (8.3.6)，可求得

$$C = 1 + \frac{1}{3(4-1)} \left[\left(\frac{1}{6} + \frac{1}{4} + \frac{1}{5} + \frac{1}{5} \right) - \frac{1}{20} \right] = 1.0856$$

再由 (8.3.7)，还可求得 Bartlett 检验统计量的值

$$B = \frac{1}{1.0856} \left[20 \times \ln 2.09 - (6 \times \ln 2.14 + 4 \times \ln 2.83 + 5 \times \ln 2.41 + 5 \times \ln 1.12) \right] = 0.970$$

对给定的显著性水平 $\alpha = 0.05$ ，查表知 $\chi_{0.95}^2(4-1) = 7.815$ 。由于 $B < 7.815$ ，故应保留原假设 H_0 ，即可认为水平下的方差间无显著差异。

8.3.3 修正的 Bartlett 检验

对于样本量低于 5 时不能使用 Bartlett 检验的缺点,
Box 提出修正的 Bartlett 检验统计量

$$B' = \frac{f_2 BC}{f_1 (A - BC)} \quad (8.3.9)$$

其中 B 与 C 如 (8.3.7) 与 (8.3.6) 所示,
且 $f_1 = r - 1$, $f_2 = \frac{r+1}{(C-1)^2}$, $A = \frac{f_2}{2 - C + 2/f_2}$

在原假设 $H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_r^2$ 成立下, Box
还明了统量 B' 的近似分布是 F 分布 $F(f_1, f_2)$,
对给定的显著性水平 α , 该检验的拒绝域为

$$W = \{B' > F_{1-\alpha}(f_1, f_2)\}$$

(8.3.10)

其中 f_2 的值可能不是整数, 这时通过对 F 分布
的分位数表施行内插法得到分位数。

例 8.3.3 对例 8.3.2 中的绿茶茶酸含量的数据，我们用修正的 Bartlett 检验再一次对等方差性作出检验

在例 8.3.2 中已求得： $C=1.0856$ ， $B=0.970$ ，还可求得：

$$f_1 = 4 - 1 = 3$$

$$f_2 = \frac{4 + 1}{(1.0856C - 1)^2} = 682.4$$

$$A = \frac{682.4}{2 - 1.0856 + 2 / 682.4} = 743.9$$

$$B' = \frac{682.4 \times 0.970 \times 1.0856}{3(743.9 - 0.970 \times 1.0856)} = 0.322$$

对给定的显著性水平 $\alpha = 0.05$ ，在 F 分布的分位数表上可查得 $F_{0.95}(3, 682.4) = F_{0.95}(3, \infty) = 2.60$

由于 $0.322 < 2.60$ ，故保留原假设 H_0 ，即认为四个水平下的方差间无显著差异。

§8.4 一元线性回归

8.4.1 变量间的两类关系

十九世纪 英国生物学家兼统计学家高尔顿研究发现

$$\hat{y} = 33.73 + 0.516x$$

其中 x 表示父亲身高, y 表示成年儿子的身高 (单位: 英寸, 1 英寸 = 2.54 厘米)。这表明子代的平均高度有向中心回归的意思, 使得一段时间内人的身高相对稳定。之后回归分析的思想渗透到了数理统计的其它分支中。

- 回归分析处理的是变量与变量间的关系。变量间常见的关系有两类：**确定性关系**与**相关关系**。
- 变量间的相关关系不能用完全确切的函数形式表示，但在平均意义下有一定的定量关系表达式，寻找这种定量关系表达式就是回归分析的主要任务。
- 回归分析便是研究变量间相关关系的一门学科。它通过对客观事物中变量的大量观察或试验获得的数据，去寻找隐藏在数据背后的相关关系，给出它们的表达形式——回归函数的估计。

8.4.2 一元线性回归模型

设 y 与 x 间有相关关系, 称 x 为自变量 (预变量), y 为因变量 (响应量), 在知道 x 取值后, y 有一个分布 $p(y|x)$, 我们关心的是 y 的均值 $E(Y|x)$:

$$f(x) = E(Y|x) = \int_{-\infty}^{\infty} yp(y|x)dy \quad (8.4.1)$$

这便是 y 关于 x 的理论回归函数——条件期望, 也就是我们要寻找的相关关系的表达式。

通常, 相关关系可用下式表示

$$y = f(x) + \varepsilon$$

其中 ε 是随机误差, 一般假设 $\varepsilon \sim N(0, \sigma^2)$ 。

进行回归分析首先是回归函数形式的选择。当只有一个自变量时，通常可采用画散点图的方法进行选择。


例 8.4.1 合金的强度 y ($\times 10^7 \text{Pa}$) 与合金中碳的含量 x (%) 有关。为研究两个变量间的关系。首先是收集数据，我们把收集到的数据记为 $(x_i, y_i), i=1, 2, \dots, n$ 。本例中，我们收集到 12 组数据，列于表 8.4.1 中

表 8.4.1 合金钢强度 y 与碳含量 x 的数据

序号	$x(\%)$	$y (\times 10^7 \text{Pa})$	序号	$x(\%)$	$y (\times 10^7 \text{Pa})$
1	0.10	42.0	7	0.16	49.0
2	0.11	43.0	8	0.17	53.0
3	0.12	45.0	9	0.18	50.0
4	0.13	45.0	10	0.20	55.0
5	0.14	45.0	11	0.21	55.0
6	0.15	47.5	12	0.23	60.0



为找出两个量间存在的回归函数的形式，可以画一张图把每一对数 (x_i, y_i) 看成直角坐标系中的一个点，在图上画出 n 个点，称这图散点图 见图 8.4.1



从散点图我们发现 2 个点基本在一条直线附近, 说明两个变量之间有一个线性相关关系, 这个相关关系可以表示为

$$y = \beta_0 + \beta_1 x + \varepsilon \quad (8.4.2)$$

这便是 y 关于 x 的一元线性回归的数据结构式。通常假定

$$E(\varepsilon) = 0, \text{Var}(\varepsilon) = \sigma^2 \quad (8.4.3)$$

在对未知参数作区间估计或假设检验时 还需要假定误差服从正态分布, 即

$$y \sim N(\beta_0 + \beta_1 x, \sigma^2) \quad (8.4.4)$$

显然, 假定 (8.4.4) 比 (8.4.3) 要强

由于 β_0, β_1 均未知, 需要我们从收集到的数据 (x_i, y_i) , $i=1, 2, \dots, n$, 出发进行估计. 在收集数据时 我们一般要求观察独立地进行,

即假定 $y_1, y_2, \dots, y_n$ 相互独立. 综合上述诸假定, 我们可以给出最简单常用的一元线性回归的数学模型:

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, & i=1, 2, \dots, n \\ \text{各 } \varepsilon_i \text{ 独立同分布, 其分布为 } N(0, \sigma^2) \end{cases} \quad (8.4.5)$$

由数据 (x_i, y_i) , $i=1, 2, \dots, n$, 可以获得 β_0, β_1 的估计 $\hat{\beta}_0, \hat{\beta}_1$, 称

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (8.4.6)$$

为关于 x 的回归函数, 简称为回归方程, 其图形称为回归直线 给定 $x=x_0$ 后,

称 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_0$ 为回归值 (在不同场合也称其为估计值 预值)。

8.4.3 回归系数的最小二乘估计

一般采用最小二乘方法估计模型 (8.4.5) 中的 β_0, β_1 :

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

$\hat{\beta}_0, \hat{\beta}_1$

应该满足

$$Q(\hat{\beta}_0, \hat{\beta}_1) = \min_{\beta_0, \beta_1} Q(\beta_0, \beta_1)$$

称这样得到的 $\hat{\beta}_0, \hat{\beta}_1$ 称为 β_0, β_1 的最小二乘估计
记为 LSE。

最小二乘估计可以通过求偏导数并令其为0 而得到:

$$\begin{cases} \frac{\partial Q}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \\ \frac{\partial Q}{\partial \beta_1} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0 \end{cases} \quad (8.4.7)$$

这方程称为正规方程组 经整理, 可得

$$\begin{cases} n \hat{\beta}_0 + n \bar{x} \hat{\beta}_1 = n \bar{y} \\ n \bar{x} \hat{\beta}_0 + \sum x_i^2 \hat{\beta}_1 = \sum x_i y_i \end{cases} \quad (8.4.8)$$

解 (8.4.8) 可得

$$\begin{cases} \hat{\beta}_1 = l_{xy} / l_{xx} \\ \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \end{cases} \quad (8.4.9)$$

这就是参数的最小二乘估计 其中

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i$$

$$l_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x} \cdot \bar{y} = \sum x_i y_i - \frac{1}{n} \sum x_i \sum y_i$$

$$l_{xx} = \sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2 = \sum x_i^2 - \frac{1}{n} \left(\sum x_i \right)^2$$

$$l_{yy} = \sum (y_i - \bar{y})^2 = \sum y_i^2 - n\bar{y}^2 = \sum y_i^2 - \frac{1}{n} \left(\sum y_i \right)^2$$



例 8.4.2 使用例 8.4.1 种合金钢强度和碳含量数据，我们可求得回归方程，见下表。

表 8.4.2 例 8.4.2 的计算表

$\sum x_i = 1.90$	$n = 12$	$\sum y_i = 590.5$
$\bar{x} = 0.1583$		$\bar{y} = 49.2083$
$\sum x_i^2 = 0.3194$	$\sum x_i y_i = 95.9250$	$\sum y_i^2 = 29392.75$
$n\bar{x}^2 = 0.3008$	$n \cdot \bar{x} \cdot \bar{y} = 93.4958$	$n\bar{y}^2 = 29057.5208$
$l_{xx} = 0.0186$	$l_{xy} = 2.4292$	$l_{yy} = 335.2292$
	$\hat{\beta}_1 = l_{xy} / l_{xx} = 130.6022$	
	$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1 = 28.5340$	

由此给出回归方程为： $\hat{y} = 28.5340 + 130.6022x$

关于最小二乘估计的一些性质罗列在如下定理之中

定理 8.4.1 在模型 (8.4.5) 下, 有

$$(1) \hat{\beta}_0 \sim N\left(\beta_0, \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}}\right) \sigma^2\right), \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right)$$

$$(2) \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}}{l_{xx}} \sigma^2$$

$$(3) \text{对给定的 } x_0, \hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \sim N\left(\beta_0 + \beta_1 x_0, \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right] \sigma^2\right)$$



定理 8.4.1 说明

- $\hat{\beta}_0, \hat{\beta}_1$ 分别是 β_0, β_1 的无偏估计;
- $\hat{y}_0$ 是 $E(y_0) = \beta_0 + \beta_1 x_0$ 的无偏估计;
- 除 $\hat{\beta}_0$ 外, $\hat{\beta}_1$ 与 $\hat{y}_0$ 是相关的;
- 要提高 $\hat{\beta}_0, \hat{\beta}_1$ 的估计精度 (即降低它们的方差) 就要求 n 大, l_{xx} 大 (即要求 $x_1, x_2, \dots, x_n$ 较分散)。

8.4.4 回归方程的显著性检验

在使用回归方程作进一步的分析以前，首先应判断回归方程是否有意义进行判断。

如果 $\beta_1=0$ ，那么不管 x 如何变化， $E(y)$ 不随 x 的变化作线性变化，那么求得的一元线性回归方程就没有意义称回归方程不显著。如果 $\beta_1 \neq 0$ ， $E(y)$ 随 x 的变化作线性变化，称回归方程是显著的。

综上，对回归方程是否有意义作判断就是要作如下的显著性检验 $H_0: \beta_1=0$ vs $H_1: \beta_1 \neq 0$

拒绝 H_0 表示回归方程是显著的。

在一元线性回归中有三种等价的检验方法，下面分别加以介绍。

一、 F 检验

采用方差分析的思想，我们从数据出发研究各 y_i 不同的原因。

数据总的波动用总偏差平方和 $S_T = \sum (y_i - \bar{y})^2 = l_{yy}$ 表示。引起各 y_i 不同的原因主要有两个因素：其一是 H_0 可能不真， $E(y)$ 随 x 的变化而变化，从而在每一个 x 的观测值处的回归值不同，其波动用回归平方和 $S_R = \sum (\hat{y}_i - \bar{y})^2$ 表示；其二是其它一切因素，包括随机误差、 x 对 $E(y)$ 的非线性影响等，这可用残差平方和 $S_e = \sum (y_i - \hat{y}_i)^2$ 表示。

且有如下平方和分解式：

$$S_T = S_R + S_e \quad (8.4.13)$$

关于 S_R 和 S_e 所含有的成分可由如下定理说明。

定理 8.4.2 设 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 其中 $\varepsilon_1, \dots, \varepsilon_n$ 相互独立, 且 $E\varepsilon_i = 0$, $Var(y_i) = \sigma^2$, $i = 1, \dots, n$, 沿用上面的记号, 有

$$E(S_R) = \sigma^2 + \beta_1^2 l_{xx} \quad (8.4.14)$$

$$E(S_e) = (n-2)\sigma^2 \quad (8.4.15)$$

这说明 $\hat{\sigma}^2 = S_e / (n-2)$ 是 σ^2 的无偏估计

进一步, 有关 S_R 和 S_e 的分布, 有如下定理。

定理 8.4.3 设 $y_1, y_2, \dots, y_n$ 相互独立, 且

$$y_i \sim N(\beta_i + \beta_1 x_i, \sigma^2), \quad i=1, \dots, n,$$

则在上述记号下, 有

$$(1) \quad S_e / \sigma^2 \sim \chi^2(n-2),$$

$$(2) \quad \text{若 } H_0 \text{ 成立, 则有 } S_R / \sigma^2 \sim \chi^2(1)$$

$$(3) \quad S_R \text{ 与 } \bar{y}, \quad \text{独立 (或 } \bar{y} \text{ 与 } S_e, \\ \text{独立)}。$$

如同方差分析那样 我们可以考虑采用 F 比作为检验量:

$$F = \frac{S_R}{S_e / (n - 2)}$$

在 $\beta_1 = 0$ 时 $F \sim F(1, n - 2)$, 其中 $f_R = 1, f_e = n - 2$.

对于给定的显著性水平 α , 拒绝域为

$$F \geq F_{1-\alpha}(1, n - 2)$$

整个检验也可列成一张方差分析表。



例 8.4.3 在合金钢强度的例 8.4.2 中，我们已求出了回归方程，这里我们考虑关于回归方程的显著性检验。经计算有

$$S_T = l_{yy} = 335.2292 \quad f_T = 11$$

$$S_R = \hat{\beta}_1^2 l_{xx} = 130.6022^2 \times 0.0186 = 317.2589, \quad f_R = 1$$

$$S_e = S_T - S_R = 335.2292 - 317.2589 = 17.9703 \quad f_e = 10$$

来源	平方和	自由度	均方和	F 比
回归	$S_R = 317.2589$	$f_A = 1$	$MS_A = 317.2589$	176.55
残差	$S_e = 17.9703$	$f_e = 10$	$MS_e = 1.79703$	
总和	$S_T = 335.2292$	$f_T = 11$		

若取 $\alpha = 0.01$ ，则 $F_{0.99}(1, 10) = 10 < F$ ，因此在显著性水平 0.01 下回归方程是显著的。

二、 t 检验

对 $H_0: \beta_1=0$ 的检验也可基于 t 分布进行。

由于

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right), \frac{S_e}{\sigma^2} \sim \chi^2(n-2), \text{ 且与 } \hat{\beta}_1 \text{ 相互独立}$$

因此在 H_0 为真时, 有

$$t = \frac{\hat{\beta}_1}{\hat{\sigma} / \sqrt{l_{xx}}} \sim t(n-2)$$

, 其中

$$\hat{\sigma} = \sqrt{S_e / (n-2)}$$

, 它可用来检验假设 H_0 。

对给定的显著性水平 α , 拒绝域为 $\{|t| > t_{1-\alpha/2}(n-2)\}$

$$\text{由于 } \sigma_{\hat{\beta}_1} = \sigma / \sqrt{l_{xx}}$$

$$\hat{\sigma}_{\hat{\beta}_1} = \hat{\sigma} / \sqrt{l_{xx}} \quad \hat{\beta}_1$$

为 β_1 的标准误, 即

的标准差的估计。

注意到 $t^2=F$, 因此, t 检验与 F 检验是等同的。

以例 8.4.2 中数据为例, 可以计算得到

$$t = \frac{130.6022}{\sqrt{1.7970 / \sqrt{0.0186}}} = 13.2872$$

若取 $\alpha = 0.01$, 则由于 $13.2872 > 3.1698$, 因此, 在显著性水平 0.01 下回归方程是显著的。



三、相关系数检验

一元线性回归方程是反映两个随机变量 x 与 y 间的线性相关关系，它的显著性检验可通过二维总体相关系数 ρ 的检验进行。它的一对假设是 $H_0: \rho = 0$

$$\text{vs } H_1: \rho \neq 0 \quad (8.4.18)$$

所用的检验统计量为样本相关系数

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} = \frac{l_{xy}}{\sqrt{l_{xx} l_{yy}}} \quad (8.4.19)$$

拒绝域为 $W = \{|r| \geq c\}$ ，其中临界值 c 应是 $H_0: \rho = 0$ 成立下 $|r|$ 的分布的 $1-\alpha$ 分位数，故记为 $c = r_{1-\alpha/2}(n-2)$ 。

由样本相关系数的定义可以得到 r 与 F 统量之间的关系

$$r^2 = \frac{F}{F + (n - 2)}$$

这表明, $|r|$ 是 F 的严格单增函数, 故可以从 F 分布的 $1-\alpha$ 分位数 $F_{1-\alpha}(1, n-2)$ 得到 $|r|$ 的 $1-\alpha$ 分位数为

$$c = r_{1-\alpha}(n-2) = \sqrt{\frac{F_{1-\alpha}(1, n-2)}{F_{1-\alpha}(1, n-2) + 1}}$$

譬如, 对 $\alpha = 0.01$, $n = 12$, $F_{0.99}(1, 10) = 10.04$, 于是

$$r_{0.99}(10) = \sqrt{\frac{10.04}{10.04 + 1}} = 0.708$$

。

为使用方便, 人们已对 $r_{1-\alpha}(n-2)$ 编制了专门的表, 见附表 9。

以例 8.4.2 中数据为例, 可以计算得到

$$r = \frac{24.4921}{\sqrt{0.0186 \times 335.2292}} = 0.9728$$

若取 $\alpha = 0.01$, 查附表 9 知 $r_{0.99}(10) = 0.708$, 由于 $0.9728 > 0.708$, 因此, 在显著性水平 0.01 下回归方程是显著的。

在一元线性回归场合，三种检验方法是等价的：在相同的显著性水平下，要么都拒绝原假设，要么都接受原假设，不会产生矛盾。

F 检验可以很容易推广到多元回归分析场合，而其他二个则否，所以， F 检验是最常用的关于回归方程显著性检验的检验方法。

8.4.5 估计与预测

当回归方程经过检验是显著的后，可用来做估计和预测。这是二个不同的问题：

(1) 当 $x=x_0$ 时，寻求均值 $E(y_0)=\beta_0+\beta_1 x_0$ 的点估计与区间估计（注意这里 $E(y_0)$ 是常量）是估计问题；

(2) 当 $x=x_0$ 时， y_0 的观察值在什么范围内？由于 y_0 是随机变量，为此只能求一个区间，使 y_0 落在这一区间的概率为 $1-\alpha$ ，即要求 δ ，使

称区间

的预测区间，

这是预测问题，
 $[y_0 - \delta, y_0 + \delta]$

$$P(|y_0 - \hat{y}_0| < \delta) \stackrel{\text{为 } y_0 \text{ 的概率为 } 1-\alpha}{=} 1-\alpha$$



一、 $E(y_0)$ 的估计

在 $x=x_0$ 时 其对应的因变量 y_0 是一个随机变量，有一个分布，我们经常需要对该分布的均值出估计 由于 $E(y_0)=\beta_0+\beta_1x_0$ ，一个直观的估计为

我们惯上将上述估计为 $\hat{E}(y_0)=\hat{\beta}_0+\hat{\beta}_1x_0$ (注意这里表示的是 $E(y_0)$ 的估计 而不表示 y_0 的估计 因为 y_0 是随机变量，它是没有估计的)。由于 $\hat{\beta}_0, \hat{\beta}_1$ 分别是 β_0, β_1 的无偏估计 因此， $\hat{E}(y_0)$ 也是 $E(y_0)$ 的无偏估计



为得到 $E(y_0)$ 的区间估计 我们需要知道 $\hat{y}_0$ 的分布。由定理 8.4.1 ,

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \sim N\left(\beta_0 + \beta_1 x_0, \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right] \sigma^2\right)$$

又由定理 8.4.3 知, $S_e / \sigma^2 \sim \chi^2(n-2)$, 且与 $\hat{y}_0 = \bar{y} + \hat{\beta}_1(x_0 - \bar{x})$ 相互独立,

故

$$\frac{(\hat{y}_0 - Ey_0) / \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \sigma}{\sqrt{\frac{S_e}{\sigma^2} / (n-2)}} = \frac{\hat{y}_0 - Ey_0}{\hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}} \sim t(n-2)$$



于是 $E(y_0)$ 的 $1-\alpha$ 的置信区间(CI) 是

$$[\hat{y}_0 - \delta_0, \quad \hat{y}_0 + \delta_0] \quad (8.4.20)$$

其中

$$\delta_0 = t_{1-\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \quad (8.4.21)$$



二、 y_0 的预区间

实用中往往更关心 $x=x_0$ 时的因变量 y_0 的取值范围 y_0 的最可能取值为 $\hat{y}_0$ 于是, 我们可以使用以 $\hat{y}_0$ 为中心的一个区间 $(\hat{y}_0 - \delta, \hat{y}_0 + \delta)$ 作为 y_0 的取值范围 推导 δ 的表达式为

$$\delta = \delta(x_0) = t_{1-\alpha/2}(n-2)\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \quad (8.4.23)$$

上述预区间 (PI) 与 $E(y_0)$ 的置信区间的差别就在于根号里多个 1。



预测区间的长度 2δ 与样本量 n 、 x 的偏差平方和 l_{xx} 、 x_0 到 $\bar{x}$ 的距离 $|x_0 - \bar{x}|$ 有关。

当 $x_0 \notin [x_{(1)}, x_{(n)}]$ 时 预测精度可能变得很差，在这种情况下的预测称作外推，需要特别小心。另外，若 $x_1, x_2, \dots, x_n$ 较集中时 那么 l_{xx} 就较小，也会导致预测精度的降低。因此，在收集数据时要使 $x_1, x_2, \dots, x_n$ 尽量分散，这提高精度有利。

当 n 较大时 (如 $n > 30$)， t 分布可以用正态分布近似，进一步，若 x_0 与 $\bar{x}$ 相差不大时 δ 可以近似取为

$$\delta \approx \sigma u_{1-\alpha/2}$$



例 8.4.4 在例 8.4.2 中, 如果 $x_0=0.16$, 则得预测值为

$$\hat{y}_0 = 28.5364 + 130.6022 \times 0.16 = 49.4328$$

若取 $\alpha = 0.05$, 则 $t_{0.975}(10) = 2.2281$,

$$s = \sqrt{17.9703 / (12 - 2)} = 1.3405$$

, 应用 (8.4.21),

$$\delta_0 = 1.3405 \times 2.2281 \times \sqrt{\frac{1}{12} + \frac{(0.16 - 0.19)^2}{0.0186}} = 1.0840$$

故 $x_0=0.16$ 对因变量 y_0 的均值 $E(y_0)$ 的 0.95 置信区间为 $(49.4328 - 1.0480, 49.4328 + 1.0480)$
 $= (48.3488, 50.5168)$



应用 (8.4.23) ,

$$\delta = 1.3405 \times 2.2281 \times \sqrt{1 + \frac{1}{12} + \frac{(0.16 - 0.19)^2}{0.0186}} = 3.1774$$

从而 y_0 的概率为 0.95 的预测区间为

$$(49.4328 - 3.1774, 49.4328 + 3.1774) = (46.2554, 52.6102)$$

$E(y_0)$ 的 0.95 置信区间比 y_0 的概率为 0.95 的预测区间窄很多, 这是因为随机变量的均值相对于随机变量本身而言要更容易估计出来。



§8.5 一元非线性回归

例 8.5.1 炼钢厂出钢时用的钢包，在使用过程中由于钢水及炉渣对耐火材料的浸蚀，其容积不断增大。现在钢包的容积用盛满水时的重量 y (kg) 表示，相应的试验次数用 x 表示。数据见表 8.5.1，要找出 y 与 x 的定量关系表达式。

表 8.5.1 钢包的重量 y 与试验次数 x 数据

序号	x	y	序号	x	y
1	2	106.42	8	11	110.59
2	3	108.20	9	14	110.60
3	4	109.58	10	15	110.90
4	5	109.50	11	16	110.76
5	7	110.00	12	18	111.00
6	8	109.93	13	19	111.20
7	10	110.49			

下面我们分三步进行。



8.5.1 确定可能的函数形式

为数据进行分析，首先描出数据的散点图
判断两个变量之间可能的函数关系，图8.5.1 是
本例的散点图

观察这3 个点构成的散点图 我们可以看到它们
并不接近一条直线 用曲线拟合这些点应该是更恰
当的，这里就涉及如何选择曲线函数形式的问题



首先, 如果可由专门知识确定回归函数形式, 则应尽可能利用专门知识。当若不能由专门知识以确定函数形式, 则可将散点图与一些常见的函数关系的图形进行比较。选几个可能的函数形式, 然后使用统方法在这些函数形式之间进行比较。最后确定合适的曲线回归方程。为此, 必须了解常见的曲线函数的图形, 见图8.5.2。



本例中，散点图呈现一个明显的向上且上凸的趋势。可能选择的函数关系有很多，比如，参照图 8.5.2，我们可以给出如下四个曲线函数：

- 1) $1/y = a + b/x$
- 2) $y = a + b \ln x$
- 3) $y = a + b\sqrt{x}$
- 4) $y - 100 = a \cdot e^{-x/b} (b > 0)$

在初步选出可能的函数关系（即方程）后，我们必须解决两个问题：如何估计所选方程中的参数？如何评价所选不同方程的优劣？



8.5.2 参数估计

对上述非线性函数，参数估计最常用的方法是“线性化”方法。

以 $1/y=a+b/x$ 为例，为了能采用一元线性回归分析方法，我们作如下变换 $u=1/x, v=1/y$ 则曲线函数就化为如下的直线 $v=bu$

这是理论回归函数。对数据而言，回归方程为

$$v_i = a + bu_i + \varepsilon_i$$

于是可用一元线性回归的方法估计出 a, b 。

表 8.5.3 参数估计计算表

$\sum u_i = 2.05088194$	$n = 13$	$\sum v_i = 0.11826672$
$\bar{u} = 0.15776015$		$\bar{v} = 0.00909744$
$\sum u_i^2 = 0.53721798$	$\sum u_i v_i = 0.01883495$	
$n\bar{u}^2 = 0.32354744$	$n\bar{u}\bar{v} = 0.01865778$	
$l_{uu} = 0.21367054$	$l_{uv} = 0.00017717$	
	$\hat{b} = l_{uv}/l_{uu} = 0.00082917$	
	$\hat{a} = \bar{v} - \bar{u}\hat{b} = 0.00896663$	
$\therefore \hat{y} = \frac{x}{0.00082917 + 0.00896663x}$		



用类似的方法可以得出其它三个曲线回归方程，
它们分别是：

$$\hat{y} = 106.3147 + 3.9466 \ln x$$

$$\hat{y} = 106.3013 + 1.1947\sqrt{x}$$

$$\hat{y} = 100 + 11.7506e^{-1.1256/x}$$



8.5.3 曲线回归方程的比较

我们上面得到了四个曲线回归方程，通常可采用如下二个指标进行选择

(1) 决定系数 R^2 ：类似于一元线性回归方程中相关系数，决定系数定义为

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (8.5.5)$$

R^2 越大，说明残差越小，回归曲线拟合越好， R^2 从总体上给出一个拟合好坏程度的度量。



(2) 剩余标准差 s ：类似于一元线性回归中标准差的估计公式，此剩余标准差可用残差平方和来获得，即

$$s = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n-2}} \quad (8.5.6)$$

s 为观测点 y_i 与由曲线给出的拟合值之间的平均偏离程度的度量， s 越小，方程越好。



在观测数据给定后，不同的曲线选择不会影响

$$\sum_{i=1}^n (y_i - \bar{y})^2$$

的取值 但会影响到残差平方和

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

的取值 因此，对选择的曲线而言，决定系数和剩余标准差都取决于残差平方和

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

，从而，两种选择准则是一致的，只是从两个不同侧面作出评价。



表 8.5.4 给出第一个曲线回归方程的残差平方和的计算过程, 由于 $n=13$, $\sum_{i=1}^{13} (y_i - \bar{y})^2 = 0.5743$, 故其决定系数及剩余标准差分别为:

$$R^2 = 1 - \frac{0.5743}{21.2105} = 0.9729, \quad s = \sqrt{\frac{0.5743}{13-2}} = 0.2285$$

其它三个方程的决定系数及剩余标准差可同样计算, 我们将它们列在表 8.5.5 中。



表 8.5.5 四种曲线回归的决定系数及剩余标准差

模型编号	1)	2)	3)	4)
R^2	0.9729	0.8773	0.7851	0.9623
s	0.2285	0.4864	0.6437	0.2696

从表 8.5.5 中可以看出，第一个曲线方程的决定系数最大，剩余标准差最小，在这四个曲线回归方程中，不论用哪个标准，都是第一个方程拟合得最好。因此，近似得比较好的定量关系式就是

$$\hat{y} = \frac{x}{0.00082917 + 0.00896663x}$$