

第六章 参数估计

- § 6.1 点估计的几种方法
- § 6.2 点估计的评价标准
- § 6.3 最小方差无偏估计
- § 6.4 贝叶斯估计
- § 6.5 区间估计

- 一般常用 θ 表示参数, 参数 θ 所有可能取值组成的集合称为参数空间 常用 Θ 表示。参数估计问题就是根据样本对上述各种未知参数作出估计
- 参数估计的形式有两种: 点估计与区间估计



- 设 $x_1, x_2, \dots, x_n$ 是来自总体 X 的一个样本, 我们用 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 的取值作为 θ 的估计值, 称为 θ 的 点估计(量), 简称 估计. 这里如何构造统量 $\hat{\theta}$ 并没有明确的规定, 只要它满足一定的合理性即可。这就涉及到两个问题:
 - 其一 是如何给出估计, 即估计的 方法问题;
 - 其二 是如何对不同的估计进行评价, 即估计的 好坏判断标准。



§6.1 点估计的几种方法

6.1.1 替换原理和矩法估计

一、矩法估计

替换原理是指用样本矩及其函数去替换相应的总体矩及其函数，譬如：

- 用样本均值估计总体均值 $E(X)$ ，即 $\hat{E}(X) = \bar{x}$ ；
- 用样本方差估计总体方差 $\text{Var}(X)$ ，即 $\hat{\text{Var}}(X) = s_n^2$
- 用样本的 p 分位数估计总体的 p 分位数，
- 用样本中位数估计总体中位数。



例 6.1.1 对某型号的 20 辆汽车记录其每加仑汽油的行驶里程 (km), 观测数据如下:

29.8	27.6	28.3	27.9	30.1	28.7	29.9	28.0
27.9	28.7	28.4	27.2	29.5	28.5	28.0	30.0
29.1	29.8	29.6	26.9				

经算有

$$\bar{x} = 28.695, \quad s_n^2 = 0.9185, \quad m_{0.5} = 28.6$$

由此给出总体均值 方差和中位数的估计分别为
28.695, 0.9185 和 28.6。

矩法估计的实质是用经验分布函数去替换总体分布, 其理论基础是格里文科定理。



二、概率函数 $P(x, \theta)$ 已知时未知参数的矩法估计

设总体具有已知的概率函数 $P(x, \theta_1, \dots, \theta_k)$, $x_1, x_2, \dots, x_n$ 是样本, 假定总体的 k 阶原点矩 μ_k 存在, 若 $\theta_1, \dots, \theta_k$ 能够表示成 $\mu_1, \dots, \mu_k$ 的函数 $\theta_j = \theta_j(\mu_1, \dots, \mu_k)$, 则可给出诸 θ_j 的矩法估计为

$$\hat{\theta}_j = \theta_j(a_1, \dots, a_k), \quad j = 1, \dots, k,$$

其中
$$a_j = \frac{1}{n} \sum_{i=1}^n x_i^j$$

例 6.1.2 设总体服从指数分布, 由于 $EX=1/\lambda$,
即 $\lambda = 1/EX$, 故 λ 的矩法估计为

$$\hat{\lambda} = 1/\bar{x}$$

另外, 由于 $\text{Var}(X)=1/\lambda^2$, 其反函数为 $\lambda = 1/\sqrt{\text{Var}(X)}$
因此, 从替换原理来看, λ 的矩法估计也可取为

$$\hat{\lambda}_1 = 1/s$$

s 为样本标准差。这说明矩估计可能是不唯一的, 这是矩法估计的一个缺点, 此时通常应尽量采用低阶矩给出未知参数的估计

例 6.1.3 $x_1, x_2, \dots, x_n$ 是来自 (a, b) 上的均匀分布 $U(a, b)$ 的样本, a 与 b 均是未知参数, 这里 $k=2$, 由于

$$EX = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12},$$

不难推出

$$a = EX - \sqrt{3\text{Var}(X)}, \quad b = EX + \sqrt{3\text{Var}(X)},$$

由此即可得到 a, b 的矩估计

$$\hat{a} = \bar{x} - \sqrt{3}s, \quad \hat{b} = \bar{x} + \sqrt{3}s$$

6.1.2 极 (最) 大似然估计

定义 6.1.1 设总体的概率函数为 $P(x; \theta)$, Θ 是参数 θ 可能取值的参数空间, $x_1, x_2, \dots, x_n$ 是样本, 将样本的联合概率函数看成 θ 的函数, 用 $L(\theta; x_1, x_2, \dots, x_n)$ 表示, 简记为 $L(\theta)$,

$$L(\theta) = L(\theta; x_1, \dots, x_n) = p(x_1; \theta) \cdot p(x_2; \theta) \cdots p(x_n; \theta)$$

称为样本的似然函数。

如果某统量 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 满足

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$$

则 $\hat{\theta}$ 是 θ 的极大似然估计 简记为 MLE
(Maximum Likelihood Estimate) 。

人们通常更习惯于由对数似然函数 $\ln L(\theta)$ 出发寻找 θ 的极大似然估计。

当 $L(\theta)$ 是可微函数时，求导是求极大似然估计最常用的方法，对 $\ln L(\theta)$ 求导更加简单些。

例 6.1.6 设一个试验有三种可能结果，其发生概率分别为 θ^2 , $2\theta(1-\theta)$, $(1-\theta)^2$ 。现做了 n 次试验，观察到三种结果发生的次数分别为 n_1, n_2, n_3 ($n_1 + n_2 + n_3 = n$)，则似然函数为

$$L(\theta) = (\theta^2)^{n_1} [2\theta(1-\theta)]^{n_2} [(1-\theta)^2]^{n_3}$$

其对数似然函数为 $\theta^{2n_1+n_2} (1-\theta)^{2n_3+n_2}$

$$\ln L(\theta) = (2n_1 + n_2) \ln \theta + (2n_3 + n_2) \ln(1-\theta) + n_2 \ln 2$$

将之关于 θ 求导 并令其为 0 得到似然方程

$$\frac{2n_1 + n_2}{\theta} - \frac{2n_3 + n_2}{1 - \theta} = 0$$

解之, 得

$$\hat{\theta} = \frac{2n_1 + n_2}{2(n_1 + n_2 + n_3)} = \frac{2n_1 + n_2}{2n}$$

由于

$$\frac{\partial^2 \ln L(\theta)}{\partial \theta^2} = -\frac{2n_1 + n_2}{\theta^2} - \frac{2n_3 + n_2}{(1 - \theta)^2} < 0$$

所以 $\hat{\theta}$ 是极大值点。

例 6.1.7 对正态总体 $N(\mu, \sigma^2)$, $\theta=(\mu, \sigma^2)$ 是二维参数, 设有样本 $x_1, x_2, \dots, x_n$, 则似然函数及其对数分别为

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x_i - \mu)^2}{2\sigma^2}\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ \ln L(\mu, \sigma^2) &= -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2} \ln \sigma^2 - \frac{n}{2} \ln(2\pi) \end{aligned}$$

将 $\ln L(\mu, \sigma^2)$ 分别关于两个分量求偏导并令其为0, 即得到似然方程组

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \quad (6.1.9)$$

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2} = 0 \quad (6.1.10)$$

解此方程组 由 (6.1.9) 可得 μ 的极大似然估计为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

将之代入 (6.1.10) , 得出 σ^2 的极大似然估计

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s^{*2}$$

利用二阶函数矩阵的非正定性可以说明上述估计使得似然函数取极大值

虽然求导函数是求极大似然估计最常用的方法，
但并不是在所有场合求导都是有效的。

例 6.1.8 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体
 $U(0, \theta)$ 的样本，试求 θ 的极大似然估计。

解 似然函数

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}$$

要使 $L(\theta)$ 达到最大, 首先一点是示性函数取值应为 1, 其次是 $1/\theta^n$ 尽可能大。由于 $1/\theta^n$ 是 θ 的单调减函数, 所以 θ 的取值尽可能小, 但示性函数为 1 决定了 θ 不能小于 $x_{(n)}$, 由此给出 θ 的极大似然估计 $\hat{\theta}_0 = x_{(n)}$

极大似然估计有一个简单而有用的性质 如果 $\hat{\theta}$ 是 θ 的极大似然估计 则任一函数 $g(\theta)$, 其极大似然估计为 $g(\hat{\theta})$ 。该性质称为极大似然估计的**不变性**, 从而使一些复杂结构的参数的极大似然估计的获得变得容易了。

例 6.1.9 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则和 σ^2 的极大似然估计为 $\hat{\sigma}^2 = s^{*2}$, 于是由不变性可得如下参数的极大似然估计它们是:

➤ 标准差 σ 的 MLE 是 s^* ;

- 概率 $P(X < 3) = \Phi\left(\frac{3 - \mu}{\sigma}\right)$ 的 MLE 是 $\Phi\left(\frac{3 - \bar{x}}{s^*}\right)$;
- 总体 0.90 分位数 $x_{0.90} = \mu + \sigma u_{0.90}$ 的 MLE 是 $\bar{x} + s^* \cdot u_{0.90}$, 其中 $u_{0.90}$ 为标准正态分布的 0.90 分位数。

§6.2 点估计的评价标准

6.2.1 相合性

我们知道，点估计是一个统量，因此它是一个随机变量，在样本量一定的条件下，我们不可能要求它完全等同于参数的真实取值。但如果我们有足够的观测，根据格里兹科定理，随着样本量的不断增大，经验分布函数逼近真实分布函数，因此完全可以要求估计量随着样本量的不断增大而逼近参数真值。这就是相合性，严格定义如下。

定义6.2.1 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 是 θ 的一个估计量, n 是样本容量, 若对任何一个 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \quad (6.2.1)$$

则称 $\hat{\theta}_n$ 为 θ 参数的相合估计

相合性被认为是估计的一个最基本要求，如果一个估计量，在样本量不断增大时它都不能把被估参数估计到任意指定的精度，那么这个估计是很值得怀疑的。通常，不满足相合性要求的估计一般不予考虑。证明估计的相合性一般可应用大数定律或直接由定义来证。

若把依赖于样本量 n 的估计量 $\hat{\theta}_n$ 看作一个随机变量序列，相合性就是依概率收敛于 θ ，所以证明估计的相合性可应用依概率收敛的性质及各种大数定律。

在判断估计的相合性时下述两个定理是很有用的。

定理 6.2.1 设 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计

定理 6.2.2 若 $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$ 分别是 $\theta_1, \dots, \theta_k$ 的相合估计

设 $g(\theta_1, \dots, \theta_k)$ 是 $\theta_1, \dots, \theta_k$ 的连续函数,

则

是 η 的相合估计。

例 6.2.2 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的样本, 证明 θ 的极大似然估计是相合估计

证明: 在例 6.1.7 中我们已经给出 θ 的极大似然估计是 $x_{(n)}$ 。由次序统量的分布, 我们知道 $x_{(n)}$ 的分布密度函数为 $p(y) = ny^{n-1}/\theta^n, y < \theta$, 故有

$$E\hat{\theta} = \int_0^\theta ny^n dy / \theta^n = \frac{n}{n+1} \theta \rightarrow \theta$$

$$E\hat{\theta}^2 = \int_0^\theta ny^{n+1} dy / \theta^n = \frac{n}{n+2} \theta^2$$

$$\text{Var}(\hat{\theta}) = \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1} \theta \right)^2 = \frac{n}{(n+1)^2 (n+2)} \theta^2 \rightarrow 0,$$

由定理 6.2.1 可知, $x_{(n)}$ 是 θ 的相合估计

由大数定律及定理 6.2.2 , 我们可以看到:
矩估计一般都具有相合性。比如:

- 样本均值是总体均值的相合估计;
- 样本标准差是总体标准差的相合估计;
- 样本变异系数是总体变异系数的相合估计。

6.2.2 无偏性

定义6.2.2 设 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 是 θ 的一个估计
 θ 的参数空间为 Θ , 若对任意的 $\theta \in \Theta$, 有
$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计 否则称为有偏估计

例 6.2.4 对任一总体而言, 样本均值是总体均值的无偏估计. 当总体 k 阶矩存在时, 样本 k 阶原点矩 a_k 是总体 k 阶原点矩 μ_k 的无偏估计. 但对中心矩则不一样. 譬如, 由于 $E(s^{*2}) = \frac{n-1}{n}\sigma^2$, 样本方差 s^{*2} 不是总体方差 σ^2 的无偏估计. 对此, 有如下两点说明:

(1) 当样本量趋于无穷时, 有 $E(s^{*2}) \rightarrow \sigma^2$,

我们称 s^{*2} 为 σ^2 的渐近无偏估计.

(2) 若对 s^{*2} 作如下修正: $s^2 = \frac{ns^{*2}}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$,

则 s^2 是总体方差的无偏估计.

例 6.2.5 设总体为 $N(\mu, \sigma^2)$, $x_1, x_2, \dots, x_n$ 是样本, 则 s^2 是 σ^2 的无偏估计, 且可求出

$$Es = \sqrt{\frac{2}{n-1}} \cdot \frac{\Gamma(n/2)}{\Gamma((n-1)/2)} \cdot \sigma \equiv \frac{\sigma}{c_n}$$

这说明 s 不是 σ 的无偏估计.

利用修正技术可得 $c_n s$ 是 σ 的无偏估计, 其中

$$c_n = \sqrt{\frac{n-1}{2}} \cdot \frac{\Gamma((n-1)/2)}{\Gamma(n/2)} \text{ 是修偏系数.}$$

可以证明, 当 $n \rightarrow \infty$ 时, 有 $c_n \rightarrow 1$.

这说明 s 是 σ 的渐近无偏估计.

6.2.3 有效性

定义6.2.3 设 $\hat{\theta}_1, \hat{\theta}_2$ 是 θ 的两个无偏估计 如果
对任意的 $\theta \in \Theta$, 有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少有一个 $\theta \in \Theta$ 使得上述不等号严格成立, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

例 6.2.6 设 $x_1, x_2, \dots, x_n$ 是取自某总体的样本, 记总体均值为 μ , 总体方差为 σ^2 , 则 $\hat{\mu}_1 = x_1$, $\hat{\mu}_2 = \bar{x}$ 都是 μ 的无偏估计 但

$$\text{Var}(\hat{\mu}_1) = \sigma^2, \quad \text{Var}(\hat{\mu}_2) = \sigma^2 / n$$

显然, 只要 $n > 1$, $\hat{\mu}_2$ 比 $\hat{\mu}_1$ 有效。这表明用全部数据的平均估计总体均值要比只使用部分数据更有效。

例 6.2.7 均匀总体 $U(0, \theta)$ 中 θ 的极大似然估计是 $x_{(n)}$,

由于 $E x_{(n)} = \frac{n}{n+1} \theta$ 所以 $x_{(n)}$ 不是 θ 的无偏估计 而是 θ 的渐近无偏估计 经修偏后可以得到 θ 的一个无偏估计。且 $\hat{\theta}_1 = \frac{n+1}{n} x_{(n)}$

$$\text{Var}(\hat{\theta}_1) = \left(\frac{n+1}{n} \right)^2 \text{Var}(x_{(n)}) = \left(\frac{n+1}{n} \right)^2 \frac{n}{(n+1)^2(n+2)} \theta^2 = \frac{\theta^2}{n(n+2)}$$

另一方面, 由矩法我们可以得到 θ 的另一个无偏估计 $\hat{\theta}_2 = 2\bar{x}$, 且

$$\text{Var}(\hat{\theta}_2) = 4 \text{Var}(\bar{x}) = \frac{4}{n} \text{Var}(X) = \frac{4}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n}$$

由此, 当 $n > 1$ 时 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

6.2.4 均方误差

无偏估计不一定比有偏估计更优

评价一个点估计的好坏一般可以用：点估计值与参数真值 θ 的距离平方的期望，这就是下式给出的均方误差

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2$$

均方误差是评价点估计的最一般的标准。我们希望估计的均方误差越小越好。

注意到 $MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2$, 因此

(1) 若 $\hat{\theta}$ 是 θ 的无偏估计 则 $MSE(\hat{\theta}) = \text{Var}(\hat{\theta})$
这说明用方差考察无偏估计有效性是合理的。

(2) 当 $\hat{\theta}$ 不是 θ 的无偏估计时 就要看其均方误差 $MSE(\hat{\theta})$

下面的例子说明：在均方误差的含义下有些有偏估计优于无偏估计

例 6.2.8 对均匀总体 $U(0, \theta)$, 由 θ 的极大似然估计得到的无偏估计是 $\hat{\theta} = (n+1)x_{(n)}/n$ 它的均方误差

$$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) = \frac{\theta^2}{n(n+2)}$$

我们考虑 θ 的形如 $\hat{\theta}_\alpha = \alpha \cdot x_{(n)}$ 的估计 其均方差为

$$MSE(\hat{\theta}_\alpha) = \alpha^2 \frac{n}{(n+1)^2(n+2)} \theta^2 + \left(\frac{n \cdot \alpha}{n+1} - 1 \right)^2 \theta^2$$

$$\alpha_0 = (n+2)/(n+1)$$

用求导的方法不难求出当

上述均方误差

达到最小 $(\hat{\theta}_0)$ 且其均方误差 $\frac{\theta^2}{(n+1)^2 n(n+2)} = MSE(\hat{\theta})$

$$\hat{\theta}_0$$

所以在均方误差的准则下, 有偏估计 优于无偏估计。

§6.3 最小方差无偏估计

6.3.1 Rao-Blackwell 定理

以下定理说明：好的无偏估计都是充分统计量的函数。

定理 6.3.2 设总体概率函数是 $p(x, \theta)$, $x_1, x_2, \dots, x_n$

是其样本, $T = T(x_1, x_2, \dots, x_n)$ 是 θ 的充分统计量, 则

对 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta} | T)$, 则 $\tilde{\theta}$ 也是 θ 的无偏估计, 且

则 $\tilde{\theta}$ 也是 θ 的无偏估计, 且

定理 6.3.2 说明: 如果无偏估计不是充分统计量的函数, 则对充分统计量求条件期望可以得到一个新的无偏估计. 该估计的方差比原来的估计的方差要小, 从而降低了无偏估计的方差. 换言之, 考虑的估计只需要在基于充分统计量的函数中进行即可, 该法对所有的统计推断问题都是正确的, 这便是所谓的**充分性原则**.

例 6.3.1 设 $x_1, x_2, \dots, x_n$ 是来自 $b(1, p)$ 的样本, 则

$T = n\bar{x}$ 是 p 的充分统量。为估计 $\theta = p^2$, 可令

$$\hat{\theta}_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1 \\ 0, & \text{其它} \end{cases}$$

由于 $E(\hat{\theta}_1) = P(x_1 = 1, x_2 = 1) = p \cdot p = \theta$, 所以 $\hat{\theta}_1$ 是 θ 的无偏估计。这个只使用了两个观测的估计并不好。下面我们利用 Rao-Blackwell 定理对之加以改进。求 $\hat{\theta}_1$ 关于充分统量 $T = \sum_{i=1}^n x_i$ 的条件期望, 得

$$\hat{\theta} = E(\hat{\theta}_1 | T = t) = \frac{\binom{n-2}{t-2}}{\binom{n}{t}} = \frac{t(t-1)}{n(n-1)}$$

6.3.2 最小方差无偏估计

定义6.3.1 对参数估计题 设 $\hat{\theta}$ 是 θ 的一个无偏估计 如果对另外任意一个 θ 的无偏估计, $\tilde{\theta}$ 在参数空间 Θ 上都有

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\tilde{\theta})$$

则称 $\hat{\theta}$ 是 θ 的一致最小方差无偏估计 简称为 **UMVUE**。如果 UMVUE 存在, 则它一定是充分统量的函数。

关于 UMVUE , 有如下一个判断准则。

定理 6.3.3 设 $x=(x_1, x_2, \dots, x_n)$ 是来自某总体的一个样

本, $\hat{\theta} = \hat{\theta}(x)$ 是 θ 的一个无偏估计 $\text{Var}(\hat{\theta}) < \infty$.

如果对任意一个满足 $E(\varphi(x))=0$ 的 $\varphi(x)$, 都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta$$

则 $\hat{\theta}$ 是 θ 的 UMVUE 。

例 6.3.2 设 $x_1, x_2, \dots, x_n$ 是来自指数分布 $Exp(1/\theta)$ 的样本, 则 $T = x_1 + \dots + x_n$ 是 θ 的充分统计量, 而 $\bar{x} = T/n$

是 θ 的无偏估计 设 $\varphi = \varphi(x_1, x_2, \dots, x_n)$ 是 0 的任一
无偏估计 则 $\int_0^\infty \int_0^\infty \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \cdots dx_n = 0$

两端对 θ 求导得

$$\int_0^\infty \cdots \int_0^\infty \frac{n\bar{x}}{\theta^2} \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \cdots dx_n = 0$$

这说明 $E(\bar{x} \cdot \varphi) = 0$, 从而 $Cov(\bar{x}, \varphi) = E(\bar{x} \cdot \varphi) - E(\bar{x}) \cdot E(\varphi) = 0$, 由

定理 6.3.3, 它是 θ 的 UMVUE。

6.3.3 Cramer-Rao 不等式

定义6.3.2 设体的概率函数 $P(x, \theta)$,

$\theta \in \Theta$ 满足下列条件:

- (1) **参数空间** Θ 是直线上的一个开区间
- (2) **支撑** $S = \{x: P(x, \theta) > 0\}$ 与 θ 无关;
- (3) **导数** $\frac{\partial}{\partial \theta} p(x; \theta)$ 对一切 $\theta \in \Theta$ 都存在;
- (4) 对 $P(x, \theta)$, **积分与微分运算**可交换次序;
- (5) **期望** $E \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2$ 存在; 则称 $I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2$

为体分布的**费希尔(Fisher)** 信息量。

费希尔信息量是数理统计学中一个基本概念，很多的统计结果都与费希尔信息量有关。如极大似然估计的渐近方差，无偏估计的方差的下界等都与费希尔信息量 $I(\theta)$ 有关。 $I(\theta)$ 的种种性质显示，“ $I(\theta)$ 越大”可被解释为样本分布中包含未知参数 θ 的信息越多。

例 6.3.3 设总体为泊松分布 $P(\lambda)$ 分布, 则

$$\ln p(x; \lambda) = x \ln \lambda - \lambda - \ln(x!)$$

$$\frac{\partial}{\partial \lambda} \ln p(x; \lambda) = \frac{x}{\lambda} - 1$$

于是

$$I(\lambda) = E\left(\frac{X - \lambda}{\lambda}\right)^2 = \frac{1}{\lambda}$$

例 6.3.4 设总体为指数分布, 其密度函数为

$$p(x; \theta) = \frac{1}{\theta} \exp \left\{ -\frac{x}{\theta} \right\}, \quad x > 0, \theta > 0$$

可以验证定义 6.3.2 的条件满足, 且

$$\frac{\partial}{\partial \theta} \ln p(x; \theta) = \frac{1}{\theta} - \frac{x}{\theta^2} = -\frac{x - \theta}{\theta^2}$$

于是

$$I(\theta) = E \left(\frac{x - \theta}{\theta^2} \right)^2 = \frac{\text{Var}(x)}{\theta^4} = \frac{1}{\theta^2}$$

定理 6.3.4 (Cramer-Rao 不等式)

设定义 6.3.2 的条件满足, $x_1, x_2, \dots, x_n$ 是来自该总体的样本, $T = T(x_1, x_2, \dots, x_n)$ 是 $g(\theta)$ 的任

一个无偏估计 $g'(\theta) = \frac{\partial g(\theta)}{\partial \theta}$ 存在, 且对 $\theta \in \Theta$

中一切 θ , 微分可在积分号下进行, 则有

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

- 上式称为克拉美 - 罗 (C-R) 不等式;
- $[g'(\theta)]^2/(nI(\theta))$ 称为 $g(\theta)$ 的无偏估计的方差的 C-R 下界, 简称 $g(\theta)$ 的 C-R 下界。
- 特别对 θ 的无偏估计 $\hat{\theta}$, 有 $\text{Var}(\hat{\theta}) \geq (nI(\theta))^{-1}$;
- 如果等号成立, 则称 $T=T(x_1, \dots, x_n)$ 是 $g(\theta)$ 的有效估计, 有效估计一定是 UMVUE。

例 6.3.5 设总体分布列为 $p(x, \theta) = \theta^x (1-\theta)^{1-x}$, $x=0,1$, 它满足定义 6.3.2 的所有条件, 可以算得该分布的费希尔信息量为 $I(\theta) = \frac{1}{\theta(1-\theta)}$ 若 $x_1, x_2, \dots, x_n$ 是该体的样本, 则 $\bar{x}$ 的 C-R 下界为 $(nI(\theta))^{-1} = \theta(1-\theta)/n$ 。因为 $\bar{x}$ 是 θ 的无偏估计且其方差等于 $\theta(1-\theta)/n$, 达到 C-R 下界, 所以 $\bar{x}$ 是 θ 的有效估计 它也是 θ 的 UMVUE。

例 6.3.6 设总体为指数分布 $Exp(1/\theta)$ ，它满足定义 6.3.2 的所有条件，例 6.3.4 中已经算出该分布的费希尔信息量为 $I(\theta) = \theta^{-2}$ ，若 $x_1, x_2, \dots, x_n$ 是样本，则 $\bar{x}$ 的 C-R 下界为 $(nI(\theta))^{-1} = \theta^2/n$ 。而 $\bar{x}$ 是 θ 的无偏估计 且其方差等于 θ^2/n ，达到了 C-R 下界，所以， $\bar{x}$ 是 θ 的有效估计 它也是 θ 的 UMVUE。

能达到 C-R 下界的无偏估计不多：

例 6.3.7 设总体为 $N(0, \sigma^2)$ ，满足定义 6.3.2 的条件，且费希尔信息量为 $I(\sigma^2) = \frac{1}{2\sigma^4}$ $\sigma = g(\sigma^2), \sigma = \sqrt{\sigma^2}$

则 σ 的 C-R 下界为 $\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{\sigma^2}{2n}$

而 σ 的 UMVUE 为 $\hat{\sigma} = \sqrt{\frac{n}{2}} \cdot \frac{\Gamma(n/2)}{\Gamma((n+1)/2)} \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$

其方差大于 C-R 下界。这表明所有 σ 的无偏估计的方差都大于其 C-R 下界。

费希尔信息量的主要作用体现在极大似然估计。

定理 6.3.5 设体 X 有密度函数 $p(x; \theta)$, $\theta \in \Theta$, Θ 为非退化区间 假定

(1) 对任意的 x , 偏导数 $\frac{\partial \ln p}{\partial \theta}$, $\frac{\partial^2 \ln p}{\partial \theta^2}$ 和 $\frac{\partial^3 \ln p}{\partial \theta^3}$ 对所有 $\theta \in \Theta$ 都存在;

(2) $\forall \theta \in \Theta$, 有 $\left| \frac{\partial p}{\partial \theta} \right| < F_1(x)$, $\left| \frac{\partial^2 p}{\partial \theta^2} \right| < F_2(x)$, $\left| \frac{\partial^3 \ln p}{\partial \theta^3} \right| < F_3(x)$

其中函数 $F_1(x)$, $F_2(x)$, $F_3(x)$ 可积

$$(3) \quad \forall \theta \in \Theta, \quad 0 < I(\theta) \equiv \int_{-\infty}^{\infty} \left(\frac{\partial \ln p}{\partial \theta} \right)^2 p(x; \theta) dx < \infty$$

若 $x_1, x_2, \dots, x_n$ 是来自该体的样本 $(x_1, \dots, x_n)$, 则存在未知参数 θ 的极大似然估计 $\hat{\theta}_n$, 且具有相合性和渐近正态性:

$$\hat{\theta}_n \overset{d}{\sim} N \left(\theta, \frac{1}{nI(\theta)} \right)$$

§6.4 贝叶斯估计

6.4.1 统计推断的基础

- 经典学派的观点：统计推断是根据样本信息对总体分布或总体的特征数进行推断，这里用到两种信息：总体信息和样本信息；
- 贝叶斯学派的观点：除了上述两种信息以外，统计推断还应该使用第三种信息：先验信息。

- (1) 总体信息：总体分布提供的信息。
- (2) 样本信息：抽取样本所得观测提供的信息。
- (3) 先验信息：人们在试验之前对要做的问题在经验和资料上总是有所了解的，这些信息对统计推断是有益的。先验信息即是抽样(试验)之前有关统计问题的一些信息。一般说来，先验信息来源于经验和历史资料。先验信息在日常生活和工作中是很重要的。

基于上述三种信息进行统推断的统学称为**贝叶斯统
计学**。它与经典统学的差别就在于是否利用先验信
息。贝叶斯统在重视使用总体信息和样本信息的同
时 还注意先验信息的收集、挖掘和加工,使它
数量化,形成先验分布,参加到统推断中来,
以提高统推断的质量。忽视先验信息的利用,有时
是一种浪费 有时会导致不合理的结论

贝叶斯学派的基本观点：任一未知量 θ 都可看作随机变量，可用一个概率分布去描述，这个分布称为先验分布；在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来得到一个关于未知量 θ 新的分布——后验分布；任何关于 θ 的统计推断都应基于 θ 的后验分布进行。

6.4.2 贝叶斯公式的密度函数形式

- 总体依赖于参数 θ 的概率函数在贝叶斯统计中记为 $P(x | \theta)$ ，它表示在随机变量 θ 取某个给定值时的条件概率函数；
- 根据参数 θ 的先验信息可确定先验分布 $\pi(\theta)$ ；
- 从贝叶斯观点看，样本 $x_1, x_2, \dots, x_n$ 的产生分两步进行：首先从先验分布 $\pi(\theta)$ 产生一个样本 θ_0 ，然后从 $P(x | \theta_0)$ 中产生一继续。这样的联合条件概率函数为 $p(x_1, \dots, x_n | \theta_0) = \prod_{i=1}^n P(x_i | \theta_0)$ ，这个分布综合了总体信息和样本信息；

- θ_0 是未知的，它是按先验分布 $\pi(\theta)$ 产生的。为把先验信息综合进去，不能只考虑 θ_0 ，对其它值发生的可能性也要加以考虑，故要用 $\pi(\theta)$ 进行综合。这样一来，样本 $x_1, \dots, x_n$ 和参数 θ 的联合分布为

$$h(x_1, x_2, \dots, x_n, \theta) = p(x_1, x_2, \dots, x_n | \theta) \pi(\theta),$$

这个联合分布把总体信息、样本信息和先验信息三种可用信息都综合进去了；

- 在没有样本信息时 人们只能依据先验分布 $\pi(\theta)$ 作出推断。在有了样本观察值 $x_1, x_2, \dots, x_n$ 之后, 则依据 $h(x_1, x_2, \dots, x_n, \theta)$ 作出推断。由于

$$h(x_1, x_2, \dots, x_n, \theta) = \pi(\theta | x_1, x_2, \dots, x_n) m(x_1, x_2, \dots, x_n),$$

其中 $m(x_1, \dots, x_n) = \int_{\Theta} h(x_1, \dots, x_n, \theta) d\theta = \int_{\Theta} p(x_1, \dots, x_n | \theta) \pi(\theta) d\theta$

是 $x_1, x_2, \dots, x_n$ 的边缘概率函数, 它与 θ 无关, 不含 θ 的任何信息。因此能用来作出推断的仅是条件分布 $\pi(\theta | x_1, x_2, \dots, x_n)$, 它的计算公式是

$$\pi(\theta | x_1, \dots, x_n) = \frac{h(x_1, \dots, x_n, \theta)}{m(x_1, \dots, x_n)} = \frac{p(x_1, \dots, x_n | \theta) \pi(\theta)}{\int_{\Theta} p(x_1, \dots, x_n | \theta) \pi(\theta) d\theta}$$

这个条件分布称为 θ 的**后验分布**，它集中了总体、样本和先验中有关 θ 的一切信息。

后验分布 $\pi(\theta | x_1, x_2, \dots, x_n)$ 的计算公式就是用密度函数表示的贝叶斯公式。它是用总体和样本对先验分布 $\pi(\theta)$ 作调整的结果，贝叶斯统计的一切推断都基于后验分布进行。

6.4.3 贝叶斯估计

基于后验分布 $\pi(\theta | x_1, x_2, \dots, x_n)$ 对 θ 所作的贝叶斯估计有多种, 常用有如下三种:

- 使用后验分布的密度函数最大值作为 θ 的点估计 称为最大后验估计
 - 使用后验分布的中位数作为 θ 的点估计 称为后验中位数估计
 - 使用后验分布的均值作为 θ 的点估计 称为后验期望估计
- 用得最多的是后验期望估计 它一般也简称为贝叶斯估计 记为 $\hat{\theta}_B$ 。

例 6.4.2 设某事件 A 在一次试验中发生的概率为 θ ，为估计 θ ，对试验进行了 n 次独立观测 其中事件 A 发生了 X 次，显然 $X|\theta \sim b(n, \theta)$ ，即

$$P(X = x | \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n$$

假若我们在试验前对事件 A 没有什么了解，从而对其发生的概率 θ 也没有任何信息。在这种情况下，贝叶斯本人建议采用“同等无知”的原则使用区间 $(0, 1)$ 上的均匀分布 $U(0, 1)$ 作为 θ 的先验分布，因为它取 $(0, 1)$ 上的每一点的机会均等。贝叶斯的这个建议被后人称为贝叶斯假设

由此即可利用贝叶斯公式求出 θ 的后验分布。具体如下：先写出 X 和 θ 的联合分布

$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n, \quad 0 < \theta < 1$$

然后求 X 的边缘分布

$$\theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

最后求出 θ 的后验分布

$$\pi(\theta | x) = \frac{h(x, \theta)}{m(x)} = \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1$$

最后的结果说明 $\theta | X \sim Be(x+1, n-x+1)$ ，其后验期望估计为

$$\hat{\theta}_B = E(\theta | x) = \frac{x+1}{n+2} \quad (6.4.4)$$

某些场合，贝叶斯估计要比极大似然估计更合理一点。比如：“抽检 3 个全是合格品”与“抽检 10 个全是合格品”，后者的质量比前者更信得过。这种差别在不合格品率的极大似然估计中反映不出来（两者都为 0），而用贝叶斯估计两者分别是 0.2 和 0.83。

由此可以看到，在这些极端情况下，贝叶斯估计比极大似然估计更符合人们的理念。



例 6.4.3 设 $x_1, x_2, \dots, x_n$ 是来自正态分布 $N(\mu, \sigma_0^2)$ 的一个样本, 其中 σ_0^2 已知, μ 未知, 假设 μ 的先验分布亦为正态分布 $N(\theta, \tau^2)$, 其中先验均值和先验方差 τ^2 均已知, 试求 μ 的贝叶斯估计

解: 样本 x 的分布和 μ 的先验分布分别为

$$p(x | \mu) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$

$$\pi(\mu) = (2\pi\tau^2)^{-1/2} \exp \left\{ -\frac{1}{2\tau^2} (\mu - \theta)^2 \right\}$$



由此可以写出 x 与 μ 的联合分布

$$h(X, \mu) = k_1 \cdot \exp \left\{ -\frac{1}{2} \left[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right] \right\}$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$ 。若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned} h(X, \mu) &= k_1 \exp \left\{ -\frac{1}{2} [A\mu^2 - 2B\mu + C] \right\} \\ &= k_1 \exp \left\{ -\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2} (C - B^2/A) \right\} \end{aligned}$$

注意到 A, B, C 均与 μ 无关, 由此容易算得样本的边际密度函数

$$m(x) = \int_{-\infty}^{\infty} h(x, \mu) d\mu = k_1 \exp \left\{ -\frac{1}{2} (C - B^2 / A) \right\} (2\pi / A)^{1/2}$$

应用贝叶斯公式即可得到后验分布

$$\pi(\mu | x) = \frac{h(x, \mu)}{m(x)} = (2\pi / A)^{1/2} \exp \left\{ -\frac{1}{2/A} (\mu - B / A)^2 \right\}$$

这说明在样本给定后, μ 的后验分布为

$$N(B/A, 1/A), \quad \text{即 } \mu | x \sim N \left(\frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-2} + \tau^{-2}} \right)$$

后验均值即为其贝叶斯估计

$$\hat{\mu} = \frac{n / \sigma_0^2}{n / \sigma_0^2 + 1 / \tau^2} \bar{x} + \frac{1 / \tau^2}{n / \sigma_0^2 + 1 / \tau^2} \theta$$

它是样本均值 与先验均值 的加权平均。

6.4.4 共轭先验分布

若后验分布 $\pi(\theta|x)$ 与 $\pi(\theta)$ 属于同一个分布族, 则称该分布族是 θ 的共轭先验分布 (族)。

- 二项分布 $b(n, \theta)$ 中的成功概率 θ 的共轭先验分布是贝塔分布 $Be(a, b)$;
- 泊松分布 $P(\theta)$ 中的均值 θ 的共轭先验分布是伽玛分布 $Ga(\alpha, \lambda)$;
- 在方差已知时 正态均值 μ 的共轭先验分布是正态分布 $N(\mu, \tau^2)$;
- 在均值已知时 正态方差 σ^2 的共轭先验分布是倒伽玛分布 $IGa(\alpha, \lambda)$ 。

§ 6.5 区间估计

6.5.1 区间估计的概念

定义 6.5.1 设 θ 是总体的一个参数, 其参数空间为 Θ , $x_1, x_2, \dots, x_n$ 是来自该总体的样本, 对给定的一个 α ($0 < \alpha < 1$), 若有两个统计量 $\hat{\theta}_L = \hat{\theta}_L(x_1, \dots, x_n)$ 和 $\hat{\theta}_U = \hat{\theta}_U(x_1, \dots, x_n)$, 若对任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha,$$

(6.5.1)

称随机区间 $\hat{\theta}_L, \hat{\theta}_U$ 为 θ 的置信水平为 $1-\alpha$ 的
置信区间 或简称 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1-\alpha$ 置信区间

$\hat{\theta}_L$ $\hat{\theta}_U$

和 分别称为 θ 的 (双侧) 置信下限和置信上
 限 .

这里置信水平 $1-\alpha$ 的含义是指在大量使用该置信区间时, 至少有 $100(1-\alpha)\%$ 的区间含有 θ .

例 6.5.1 设 $x_1, x_2, \dots, x_{10}$ 是来自 $N(\mu, \sigma^2)$ 的样本, 则
的置信水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{x} - t_{1-\alpha/2}(9)s/\sqrt{10}, \quad \bar{x} + t_{1-\alpha/2}(9)s/\sqrt{10} \right]$$

其中, $\bar{x}$, s 分别为样本均值和样本标准差。这个置信区间的由来将在 6.5.3 节中说明, 这里用它来说明置信区间的含义

若取 $\alpha = 0.10$, 则 $t_{0.95}(9) = 1.8331$, 上式化为

$$[\bar{x} - 0.5797s, \quad \bar{x} + 0.5797s]$$

现假定 $\mu = 15, \sigma^2 = 4$, 则我们可以用随机模拟方法由 $N(15, 4)$ 产生一个容量为 10 的样本, 如下即是这样一个样本:


14.85 13.01 13.50 14.93 16.97
13.80 17.9533 13.37 16.29 12.38

由该样本可以算得 $\bar{x} = 14.7053, s = 1.8438$

从而得到 μ 的一个区间估计为


$$[14.7053 - 0.5797 \times 1.8438, 14.7053 + 0.5797 \times 1.8438] = [13.6427, 15.7679]$$

该区间包含 μ 的真值 15。重复这样的方法 100 次, 可以得到 100 个样本, 也就得到 100 个区间。我们将这 100 个区间画在图 6.5.1 上。



由图6.5.1
可以看出,
这100个区
间中有91
个包含参
数真值5,
另外9个
不包含参
数真值

图 6.5.1 μ 的置信水平为 0.90 的置信区间



取 $\alpha=0.50$ ，
我们也可以给出 100 个这样的区间 见图 6.5.2。可以看出，这 100 个区间中有 50 个包含参数真值 5，另外 50 个不包含参数真值

图 6.5.2 μ 的置信水平为 0.50 的置信区间

定义6.5.2 沿用定义6.5.1 的记号, 如给定的 α ($0 < \alpha < 1$), 对任意的 $\theta \in \Theta$, 有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha \quad (6.5.)$$

2) $[\hat{\theta}_L, \hat{\theta}_U]$

称 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 θ 的 $1 - \alpha$ 同等置信区间

同等置信区间是把给定的置信水平 $1 - \alpha$ 用足了。

常在总体为连续分布场合下可以实现



定义 若对给定的 α ($0 < \alpha < 1$) 和任意的 $\theta \in \Theta$, 有

$P_{\theta}(\hat{\theta}_L \leq \theta) \geq 1 - \alpha$, 则称 $\hat{\theta}_L$ 为 θ 的置信水平为 $1 - \alpha$ 的

(单侧) 置信下限。假如等号对一切 $\theta \in \Theta$ 成立, 则称为 θ 的 $1 - \alpha$ 同等置信下限。若对给定的 α ($0 < \alpha < 1$) 和任意的 $\theta \in \Theta$, 有 $P_{\theta}(\hat{\theta}_U \geq \theta) \geq 1 - \alpha$, 则称为 θ 的置信水平为 $1 - \alpha$ 的 (单侧) 置信上限。若等号对一切 $\theta \in \Theta$ 成立, 则称为 $1 - \alpha$ 同等置信上限。

单侧置信限是置信区间的特殊情形。因此, 寻求置信区间的方法可以用来寻找单侧置信限。

6.5.2 枢轴量法

构造未知参数 θ 的置信区间的最常用的方法是枢轴量法，其步骤可以概括为如下三步：

1. 设法构造一个样本和 θ 的函数 $G=G(x_1, x_2, \dots, x_n, \theta)$ 使得 G 的分布不依赖于未知参数。一般称具有这种性质的 G 为枢轴。

2. 适当地选两个常数 c, d , 使对给定的 α ($0 < \alpha < 1$) 有

$$P(c \leq G \leq d) = 1 - \alpha$$

3. 假如能将 $c \leq G \leq d$ 进行不等式等价变形化为 $\hat{\theta}_L \leq \theta \leq \hat{\theta}_U$ 则 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1 - \alpha$ 同等置信区间

关于置信区间的构造有**两点说明**:

- 满足置信度要求的 c 与 d 通常不唯一。若有可能, 应选平均长度 $E(\hat{\theta}_U - \hat{\theta}_L)$ 达到最短的 c 与 d , 这在 G 的分布为对称分布场合通常容易实现。
- 实际中, 选平均长度 $E(\hat{\theta}_U - \hat{\theta}_L)$ 尽可能短的 c 与 d , 这往往很难实现, 因此, 常这样选择 c 与 d , 使得两个尾部概率各为 $\alpha/2$, 即 $P(G < c) = P(G > d) = \alpha/2$, 这样的置信区间称为等尾置信区间。这是在 G 的分布为偏态分布场合常采用的方法。

例 6.5.2 设 $x_1, x_2, \dots, x_n$ 是来自均匀总体 $U(0, \theta)$ 的一个样本, 试给定的 α ($0 < \alpha < 1$) 给出 θ 的 $1-\alpha$ 同等置信区间

解: (1) 取 $x_{(n)}$ 作为枢轴量, 其密度函数为

$$p(y; \theta) = ny^n, \quad 0 < y < 1;$$

(2) $x_{(n)}/\theta$ 的分布函数为 $F(y) = y^n, 0 < y < 1$, 故

$$P(c \leq x_{(n)}/\theta \leq d) = d^n - c^n,$$

因此我们可以适当地选择 c 和 d 满足 $d^n - c^n = 1 - \alpha$

(3) 利用不等式变形可容易地给出 θ 的 $1-\alpha$ 同
 等置信区间为 $[x_{(n)}/d, x_{(n)}/c]$, 该区间的平均长度为
 $\left(\frac{1}{c} - \frac{1}{d}\right) E x_{(n)}$ 。不难看出, 在 $0 \leq c < d \leq 1$ 及 $d_1^n - c_1^n = 1 - \alpha$
 α 的条件下, 当 $d=1, c = \frac{\sqrt{\alpha}}{1-\sqrt{\alpha}}$ 时取得
 最小值。这说明 $[x_{(n)}/\sqrt{\alpha}, x_{(n)}/(1-\sqrt{\alpha})]$ 是 θ 的置信水平 $1-\alpha$
 为最短置信区间。

6.5.3 单个正态总体参数的置信区间

一、 σ 已知时的置信区间

在这种情况下，枢轴量可选为 $G = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$ 和 d 应满足

$P(c \leq G \leq d) = \Phi(d) - \Phi(c) = 1 - \alpha$ ，经不等式变形可得

$$P_{\mu} \left(\bar{x} - d\sigma/\sqrt{n} \leq \mu \leq \bar{x} - c\sigma/\sqrt{n} \right) = 1 - \alpha$$

该区间长度为 $(d - c)\sigma/\sqrt{n}$ 。当 $d = -c = u_{1-\alpha/2}$ 时 $d - c$ 达到最小，由此给出了的同等置信区间为

$$\left[\bar{x} - u_{1-\alpha/2} \sigma/\sqrt{n}, \bar{x} + u_{1-\alpha/2} \sigma/\sqrt{n} \right]。 \quad (6.5.8)$$

这是一个以 $\bar{x}$ 为中心，半径为 $u_{1-\alpha/2} \sigma/\sqrt{n}$ 的对称区间。常将之表示为

例 6.5.3 用天平秤某物体的重量 9 次，得平均值为

$$\bar{x} = 15.4$$

(克)，已知天平秤量结果为正态分布，其标准差为 0.1 克。试求该物体重量的 0.95 置信区间

解：此处 $1 - \alpha = 0.95$ ， $\alpha = 0.05$ ，查表知 $u_{0.975} = 1.96$ ，于是该物体重量 μ 的 0.95 置信区间为

从而该物体重量的 0.95 置信区间为

$$\bar{x} \pm u_{\alpha/2} \sigma / \sqrt{n} = 15.4 \pm 1.96 \times 0.1 / \sqrt{9} = 15.4 \pm 0.0653$$

$$[15.3347, 15.4653]。$$

例 6.5.4 设总体为正态分布 $N(\mu, 1)$ ，为得到 μ 的置信水平为 0.95 的置信区间宽度不超过 0.2，样本容量应多大？

解：由题条件知 μ 的 0.95 置信区间为

$$\left[\bar{x} - u_{1-\alpha/2} / \sqrt{n}, \quad \bar{x} + u_{1-\alpha/2} / \sqrt{n} \right]$$

其区间宽度为 $2u_{1-\alpha/2} / \sqrt{n}$ ，它依赖于样本容量 n 而与样本具体取值无关。要求 $2u_{1-\alpha/2} / \sqrt{n} \leq 0.2$ ，立即有 $n \geq (2/0.2)^2 u_{1-\alpha/2}^2$ 。现 $1-\alpha = 0.95$ ，故 $u_{1-\alpha/2} = 1.96$ ，从而 $n \geq (5/0.2)^2 \cdot 1.96^2 = 10.67 \approx 11$ 。即样本容量至少为 11 才能使得 μ 的置信水平为 0.95 的置信区间宽度不超过 0.2。

二、 σ^2 未知时 μ 的置信区间

这时可用 t 统计量, 因为 $\frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$, 因此 t 可以用来作为枢轴量。完全类似于上一小节, 可得到 μ 的 $1-\alpha$ 置信区间为

$$\left[\bar{x} - t_{1-\alpha/2}(n-1)s/\sqrt{n}, \quad \bar{x} + t_{1-\alpha/2}(n-1)s/\sqrt{n} \right]$$

$$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$$

此处

是 σ^2 的无偏估计。

例 6.5.5 假设胎的寿命服从正态分布。为估计某种轮胎的平均寿命，现随机地抽 12 只轮胎试用，测得它们的寿命（单位：万公里）如下：

4.68 4.85 4.32 4.85 4.61 5.02

5.20 4.60 4.58 4.72 4.38 4.70

此处正态总体标准差未知，可使用 t 分布求均值的置信区间。经算有 $\bar{x} = 4.7092$ ， $s^2 = 0.0615$ 。取 $\alpha = 0.05$ ，查表知 $t_{0.975}(11) = 2.2010$ ，于是平均寿命的 0.95 置信区间为（单位：万公里）

$$4.7092 \pm 2.2010 \cdot \sqrt{0.0615} / \sqrt{12} = [4.5516, 4.8668]$$

在实际问题中，由于轮胎的寿命越长越好，因此可以只求平均寿命的置信下限，也即构造单侧的置信下限。由于

$$P(t_{\alpha}(n-1) < \frac{\sqrt{n}(\bar{x} - \mu)}{s}) = 1 - \alpha$$

由不等式变形可知 μ 的 $1-\alpha$ 置信下限为

$$\bar{x} - t_{1-\alpha}(n-1)s/\sqrt{n}$$

将 $t_{0.95}(11) = 1.7959$ 代入计算可得平均寿命 μ 的 0.95 置信下限为 4.5806（万公里）。

三、 σ^2 的置信区间

取枢轴量 $G = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$ ，由于 χ^2 分布是偏态分布，
寻找平均长度最短区间很难实现。一般都用等尾置信区间。
采用 χ^2 的两个分位数 $\chi^2_{\alpha/2}(n-1)$ 和 $\chi^2_{1-\alpha/2}(n-1)$ ，在 χ^2 分布两侧各截面积为 $\alpha/2$ 的部分，

$$\text{使得 } P\left(\chi^2_{\alpha/2} \leq \frac{(n-1)s^2}{\sigma^2} \leq \chi^2_{1-\alpha/2}\right) = 1 - \alpha$$

由此给出 σ^2 的 $1-\alpha$ 置信区间为

$$\left[(n-1)s^2 / \chi^2_{1-\alpha/2}(n-1), (n-1)s^2 / \chi^2_{\alpha/2}(n-1) \right]$$

例 6.5.6 某厂生产的零件重量服从正态分布 $N(\mu, \sigma^2)$ ，现从该厂生产的零件中抽取 9 个，测得其重量为(单位：克)

45.3 45.4 45.1 45.3 45.5 45.7 45.4 45.3 45.6

试求总体标准差 σ 的 0.95 置信区间

解：由数据可算得 $s^2 = 0.0325$ ， $(n-1)s^2 = 8 \times 0.0325 = 0.26$ 。

查表知 $\chi^2_{0.025}(8) = 2.1797$ ， $\chi^2_{0.975}(8) = 17.5345$ ，

代入可得 σ^2 的 0.95 置信区间为

$$\left[\frac{0.26}{17.5345}, \frac{0.26}{2.1797} \right] = [0.0148, 0.1193]$$

从而 σ 的 0.95 置信区间为 $[0.1218, 0.3454]$ 。

6.5.4 大样本置信区间

在样本容量充分大时 可以用渐近分布来构造近似的置信区间 一个典型的例子是关于比例 p 的置信区间

设 $x_1, \dots, x_n$ 是来自 $b(1, p)$ 的样本, 有 $\frac{\bar{x} - p}{\sqrt{p(1-p)/n}} \sim N(0, 1)$

对给定 α $P\left(\left|\frac{\bar{x} - p}{\sqrt{p(1-p)/n}}\right| \leq u_{1-\alpha/2}\right) = 1 - \alpha$, 通过变形,

可得到置信区间为

$$\left[\frac{1}{1 + \frac{\lambda}{n}} \left(\bar{x} + \frac{\lambda}{2n} - \sqrt{\frac{\bar{x}(1-\bar{x})\lambda}{n} + \frac{\lambda^2}{4n^2}} \right), \frac{1}{1 + \frac{\lambda}{n}} \left(\bar{x} + \frac{\lambda}{2n} + \sqrt{\frac{\bar{x}(1-\bar{x})\lambda}{n} + \frac{\lambda^2}{4n^2}} \right) \right]$$

其中记 $\lambda = u_{1-\alpha/2}^2$, 实用中通常略去 λ/n 项, 于是

可将置信区间近似为 $\left[\bar{x} - u_{\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}, \bar{x} + u_{\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \right]$

例 6.5.7 对某事件 A 作 120 次观察, A 发生 36 次。试给出事件 A 发生概率 p 的 0.95 置信区间

解: 此处 $n=120$, $\bar{x} = 36/120=0.3$ 而 $u_{0.975}=1.96$, 于是 p 的 0.95 (双侧) 置信下限和上限分别为

$$\hat{p}_L = 0.3 - 1.96 \times \sqrt{\frac{0.3 \times 0.7}{120}} = 0.218$$

$$\hat{p}_U = 0.3 + 1.96 \times \sqrt{\frac{0.3 \times 0.7}{120}} = 0.382$$

故所求的置信区间为 $[0.218, 0.382]$

例 6.5.8 某传媒公司欲调查某综艺节目收视率 p ，为使得 p 的 $1-\alpha$ 置信区间长度不超过 d_0 ，问至少需要多少用户？

解：这是关于二点分布比例 p 的置信区间问题，由 (6.5.11) 知， $1-\alpha$ 的置信区间长度为 $2u_{1-\alpha/2}\sqrt{\bar{x}(1-\bar{x})/n}$ 。这是一个随机变量，但由 $(0,1)$ ，所以对任意的观测值有 $\bar{x}(1-\bar{x}) \leq 0.5^2 = 0.25$ 。这也就是说 p 的 $1-\alpha$ 的置信区间长度不会超过 $2u_{1-\alpha/2}/\sqrt{n}$ 。现要求 p 的置信区间长度不超过 d_0 ，只需要 $2u_{1-\alpha/2}/\sqrt{n} \leq d_0$ 即可，从而

$$n \geq \left(\frac{2u_{1-\alpha/2}}{d_0} \right)^2 \quad (6.5.12)$$

这是一类常见的寻求样本量的问题 比如, 若取 $d_0=0.04$, $\alpha=0.05$, 则

$$n \geq \left(\frac{u_{0.975}}{0.04} \right)^2 = \left(\frac{1.96}{0.04} \right)^2 = 2401 \quad .$$

这表明, 要使综艺节目收视率 p 的 0.95 置信区间的长度不超过 0.04, 则需要对 2401 个用户作调查

6.5.5 两个正态总体下的置信区间

设 $x_1, \dots, x_m$ 是来自 $N(\mu_1, \sigma_1^2)$ 的样本, $y_1, \dots, y_n$ 是来自 $N(\mu_2, \sigma_2^2)$ 的样本, 且两个样本相互独立。 $\bar{x}$ 与 $\bar{y}$

$$s_x^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2 \quad \text{和} \quad s_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

分别是它们的样本均值和样本方差。下面讨论两个均值差和两个方差比的置信区间

一、 $\mu_1 - \mu_2$ 的置信区间

1、 σ_1^2 和 σ_2^2 已知时的两样本 u 区间

$$\left[\bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \quad \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right]$$

2、 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知时的两样本 t 区间

$$\left[\bar{x} - \bar{y} - \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2), \quad \bar{x} - \bar{y} + \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2) \right]$$

3、 $\sigma_2^2/\sigma_1^2=\theta$ 已知时的两样本 t 区间

$$\left[\bar{x} - \bar{y} - \sqrt{\frac{mn}{m\theta + n}} s_t t_{1-\alpha/2}(m+n-2), \quad \bar{x} - \bar{y} + \sqrt{\frac{mn}{m\theta + n}} s_t t_{1-\alpha/2}(m+n-2) \right]$$

4、当 m 和 n 都很大时的近似置信区间

$$\left[\bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}}, \quad \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}} \right]$$

5、一般情况下的近似置信区间

$$\left[\bar{x} - \bar{y} - s_0 t_{1-\alpha/2}(l), \quad \bar{x} - \bar{y} + s_0 t_{1-\alpha/2}(l) \right]$$

其中 $s_0^2 = s_x^2 / m + s_y^2 / n$, $l = \frac{s_0^4}{\frac{s_x^4}{m^2(m-1)} + \frac{s_y^4}{n^2(n-1)}}$



例 6.5.9 为比较两个小麦品种的产量，选择 8 块条件相似的试验田，采用相同的耕作方法作试验。结果播种甲品种的 8 块试验田的亩量和播种乙品种的 10 块试验田的亩量（单位：千克/亩）分别为

甲品种 628 583 510 554 612 523 530 615

乙品种 535 433 398 470 567 480 498 560

503 426

假定亩量均服从正态分布，试求这两个品种平均亩产量差的置信区间（ $\alpha=0.05$ ）。



解：以 $x_1, \dots, x_8$ 记甲品种的亩量， $y_1, \dots, y_{10}$ 记乙品种的亩量，由样本数据可计算得到

$$\bar{x} = 569.3750, \quad s_x^2 = 2140.5536, \quad m = 8$$

$$\bar{y} = 487.0000, \quad s_y^2 = 3256.2222, \quad n = 10$$

下面分两种情况讨论



(1) 若已知两个品种亩量的标准差相同, 则可采用两样本 t 区间 此处

$$s_w = \sqrt{\frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2}} = \sqrt{\frac{7 \times 2110.5536 + 9 \times 3256.2222}{16}} = 52.4880$$

$$t_{1-\alpha/2}(m+n-2) = t_{0.975}(16) = 2.1199$$

$$t_{1-\alpha/2}(m+n-2)s_w\sqrt{\frac{1}{m} + \frac{1}{n}} = 2.1199 \times 52.4880 \times \sqrt{\frac{1}{8} + \frac{1}{10}} = 52.7797$$

故 $\mu_1 - \mu_2$ 的 0.95 置信区间为

$$[569.3750 - 487 - 52.7797, \quad 9569.3750 - 487 + 52.7797] = [29.5953, \quad 135.1547]$$



(2) 若两个品种亩量的方差不等, 则可采用近似 t 区间 此处

$$s_0^2 = 2110.5536/8 + 3256.2222/10 = 589.4414,$$

$$s_0 = 24.2784$$

$$l = \frac{589.4414^2}{\frac{2110.5536^2}{8^2 \times 7} + \frac{3256.2222^2}{10^2 \times 11}} = 17.7429 \approx 18$$

$$s_0 t_{0.975}(l) = 24.2784 \times 2.1009 = 51.0065$$

于是 $\mu_1 - \mu_2$ 的 0.95 近似置信区间为

$$[31.3685, 133.3815]$$



二、 σ_1^2/σ_2^2 的置信区间

由于 $(m-1)s_x^2/\sigma_1^2 \sim \chi^2(m-1)$, $(n-1)s_y^2/\sigma_2^2 \sim \chi^2(n-1)$,
且 s_x^2 与 s_y^2 相互独立, 故可仿照 F 变量构造如下枢

轴量 $F = \frac{s_x^2/\sigma_1^2}{s_y^2/\sigma_2^2} \sim F(m-1, n-1)$, 对给定的 $1-\alpha$, 由

$$P\left(F_{\alpha/2}(m-1, n-1) \leq \frac{s_x^2}{s_y^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \leq F_{1-\alpha/2}(m-1, n-1)\right) = 1-\alpha$$

经不等式变形即给出 σ_1^2/σ_2^2 的如下的置信区间

$$\left[\frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{1-\alpha/2}(m-1, n-1)}, \quad \frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{\alpha/2}(m-1, n-1)} \right]$$



例 6.5.10 某车房有两台自动机床加工一类套筒，假设套筒直径服从正态分布。现在从两个班次的产品中分别查了 5 个和 6 个套筒，得其直径数据如下（单位：厘米）：

甲班： 5.06 5.08 5.03 5.00 5.07

乙班： 4.98 5.03 4.97 4.99 5.02 4.95

试求两班加工套筒直径的方差比 $\sigma_{\text{甲}}^2/\sigma_{\text{乙}}^2$ 的 0.95 置信区间

解： $F_{0.025}(4,5) = \frac{1}{F_{0.975}(5,4)} = \frac{1}{9.36} = 0.1068$ $F_{0.975}(4,5) = 7.39$

由数据算得 $s_x^2=0.00037$, $s_y^2=0.00092$, 故置信区间
[0.0544 , 3.7657]